تحلیل داده‌محور پزشکی

پیش‌بینی بستری مجدد ظرف ۳۰ روز در بیماران مبتلا به دیابت

تحلیل آماری و یادگیری ماشین آگاه از نشت داده بر روی ۱۰۱,۷۶۶ مراجعه‌ی بیمارستانی

عاطفه اسدی

ایمان جمشیدی

مهدیه میرزایی ولوجردی

Atefe Asadi · Iman Jamshidi · Mahdiyeh Mirzaei Valojerdie

مقاله‌ی پژوهشی / گزارش علم داده‌های پزشکی

تحلیل هم‌گروهی مشاهده‌ای · آماره‌های اندازه‌ی اثر · یادگیری ماشین

اعتبارسنجی گروه‌بندی‌شده بر اساس بیمار · تحلیل خطا در زیرگروه‌ها

مجموعه‌داده:	مجموعه‌داده‌ی «دیابت، ۱۳۰ بیمارستان آمریکا، سال‌های ۱۹۹۹ تا ۲۰۰۸»
پیامد اصلی:	بستری مجدد ظرف ۳۰ روز (30 >)
جامعه‌ی مورد مطالعه:	۱۰۱,۷۶۶ مراجعه‌ی بیمارستانی
هم‌گروه مدل‌سازی:	۹۹,۳۴۳ مراجعه پس از حذف پرونده‌های فوت/هاسپیس
چارچوب اصلی مدل‌سازی:	رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی، XGBoost
نرم‌افزار:	Python, pandas, SciPy, scikit-learn, XGBoost, Matplotlib, Seaborn

تهیه‌شده به‌صورت دست‌نوشته‌ی تحلیلی در قالب مقاله‌ی علمی

نسخه‌ی تهیه‌شده از آرشیو پروژه‌ی ارائه‌شده

اکتبر ۲۰۲۶ (مهر ۱۴۰۵)

چکیده

زمینه: بستری مجدد ظرف ۳۰ روز، پیامدی مهم برای سنجش کیفیت مراقبت و هماهنگی خدمات درمانی است، به‌ویژه در بیماران مبتلا به بیماری‌های مزمن پیچیده. مراجعه‌های بیمارستانی مرتبط با دیابت با تشخیص‌های ناهمگن، بیماری‌های همراه، مواجهه‌ی دارویی، سابقه‌ی استفاده از خدمات درمانی و مسیرهای متنوع ترخیص همراه‌اند. مدل‌های پیش‌بینی می‌توانند به طبقه‌بندی ریسک کمک کنند، اما عدم توازن کلاس‌ها، مراجعه‌های مکرر یک بیمار، مصنوعات کدگذاری و ناپایداری عملکرد در زیرگروه‌ها ممکن است نتایجی گمراه‌کننده و بیش‌ازحد خوش‌بینانه به بار آورند.

هدف: توصیف عوامل مرتبط با بستری مجدد زودهنگام و ارزیابی مدل‌های یادگیری ماشین در سطح بیمار و آگاه از نشت داده، برای شناسایی مراجعه‌هایی که ظرف ۳۰ روز با بستری مجدد دنبال شده‌اند.

روش‌ها: این تحلیل از ۱۰۱,۷۶۶ مراجعه‌ی موجود در مجموعه‌داده‌ی «دیابت، ۱۳۰ بیمارستان آمریکا» استفاده کرد. تحلیل اکتشافی شامل شمارش مراجعه‌ها، نرخ‌های ویژه‌ی هر پیامد، تفاوت‌های میانگین استانداردشده (SMD)، ضریب V کرامر، همبستگی پیرسون و غربالگری با دامنه‌ی بین‌چارکی بود. برای پیش‌بینی، پس از حذف ترخیص‌های منجر به فوت یا هاسپیس، ۹۹,۳۴۳ مراجعه باقی ماند. با GroupShuffleSplit بر اساس شناسه‌ی بیمار، یک تقسیم آموزش/آزمون ۸۰/۲۰ بدون هیچ هم‌پوشانی بیماری ساخته شد. مدل‌های رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی و XGBoost در شرایط عدم توازن کلاس‌ها ارزیابی شدند. آستانه‌های بازیابی‌محور با امتیاز F_2 در مجموعه‌ی اعتبارسنجی انتخاب شد. یک مدل XGBoost مرحله‌ی دوم با اعتبارسنجی متقاطع تصادفی گروه‌بندی‌شده بهینه شد. عملکرد در زیرگروه‌ها با بازیابی (Recall) و نرخ منفی کاذب (FNR) در نژاد، جنسیت و گروه‌های سنی بررسی شد.

یافته‌ها: بستری مجدد زودهنگام در ٪۱۱/۱۶ از کل مراجعه‌ها (۱۱,۳۵۷ از ۱۰۱,۷۶۶) و در ٪۱۱/۳۹ از هم‌گروه مدل‌سازی رخ داد. سابقه‌ی بستری قبلی روشن‌ترین سیگنال عددی بود: میانگین بستری‌های قبلی در بستری‌های مجدد زودهنگام ۱/۲۲ و در مراجعه‌های بدون بستری مجدد زودهنگام ۰/۳۸ بود ($\mathrm{SMD} = 0.415$). مقادیر V کرامر در مجموع کوچک بودند و مقصد ترخیص بیشترین ارتباط طبقه‌ای را داشت ($V = 0.125$). مدل XGBoost مرحله‌ی الف به $\mathrm{ROC\text{-}AUC} = 0.683$ و $\mathrm{PR\text{-}AUC} = 0.238$ رسید. جایگزینی آستانه‌ی پیش‌فرض ۰/۵۰ با آستانه‌ی ۰/۴۱ که روی مجموعه‌ی اعتبارسنجی تنظیم شد، بازیابی XGBoost را از ۰/۵۹۸ به ۰/۷۹۷ رساند، در حالی که ROC-AUC و PR-AUC تغییری نکردند؛ بهای این افزایش، کاهش دقت (Precision) از ۰/۱۸۸ به ۰/۱۵۲ و کاهش صحت (Accuracy) از ۰/۶۶۳ به ۰/۴۷۴ بود و حدود ٪۵۹ از مراجعه‌های مجموعه‌ی آزمون علامت‌گذاری شدند. مدل نهایی XGBoost با ابرپارامترهای جست‌وجوشده، در آستانه‌ی ۰/۵۰ به بازیابی ۰/۶۱۹، دقت ۰/۱۸۱، F1 برابر ۰/۲۸۰ و ROC-AUC نزدیک به ۰/۶۸ دست یافت. شکاف FNR میان گروه‌های سنی در هر چهار مدل شدید بود (از ۰/۸۸۵ تا ۰/۹۶۷، و $\mathrm{FNR} = 1.00$ دست‌کم در یک گروه سنی)؛ جوان‌ترین گروه‌های سنی درگیر فقط ۱ و ۶ بستری مجدد زودهنگام داشتند، بنابراین بزرگی دقیق این شکاف نامطمئن است، اما نمی‌توان مدل‌ها را برای این بیماران بدون اعتبارسنجی جداگانه ایمن دانست.

نتیجه‌گیری: سابقه‌ی بستری قبلی و مقصد ترخیص، پایدارترین سیگنال‌های پیش‌بینی‌کننده بودند، در حالی که توان تفکیک کلی در حد متوسط ماند. یافته‌ها از به‌کارگیری مدل به‌عنوان ابزار کمکی طبقه‌بندی ریسک با بازبینی انسانی پشتیبانی می‌کنند، نه تصمیم‌گیری بالینی خودکار. پیش از هرگونه استقرار بالینی، اعتبارسنجی بیرونی و به‌روز، ارزیابی کالیبراسیون، بازه‌های عدم قطعیت و نمونه‌های بزرگ‌تر در زیرگروه‌ها ضروری است.

واژه‌های کلیدی: دیابت؛ بستری مجدد بیمارستانی؛ بستری مجدد ظرف ۳۰ روز؛ تحلیل داده‌های سلامت؛ یادگیری ماشین؛ XGBoost؛ طبقه‌بندی نامتوازن؛ آستانه‌ی تصمیم؛ نشت داده در سطح بیمار؛ انصاف الگوریتمی؛ طبقه‌بندی ریسک.

فهرست مطالب

۱ مقدمه ۱

۲ زمینه‌ی بالینی و تحلیلی ۱

۲.۱ بستری مجدد ظرف ۳۰ روز به‌عنوان یک پیامد پزشکی ۱

۲.۲ چرا عدم توازن کلاس‌ها اهمیت دارد ۲

۲.۳ توان تفکیک و رتبه‌بندی ۲

۳ مواد و روش‌ها ۲

۳.۱ منبع داده و هم‌گروه مطالعه ۲

۳.۲ کیفیت داده و پیش‌پردازش ۳

۳.۳ تحلیل آماری اکتشافی ۴

۳.۴ کنترل نشت در سطح بیمار ۵

۳.۵ مدل‌های یادگیری ماشین ۶

۳.۶ بهینه‌سازی آستانه ۶

۳.۷ جست‌وجوی ابرپارامتر ۶

۳.۸ تحلیل زیرگروه‌ها ۷

٤ یافته‌ها ۷

۴.۱ توزیع پیامد بستری مجدد ۷

۴.۲ توزیع هدف دودویی ۷

۴.۳ توزیع سنی ۸

۴.۴ مصرف قبلی خدمات و طول مدت اقامت ۱۰

۴.۵ تفاوت‌های استانداردشده ۱۱

۴.۶ ساختار همبستگی ۱۲

۴.۷ ارتباط‌های طبقه‌ای ۱۳

۴.۸ نژاد و جنسیت ۱۳

۴.۹ گروه تشخیص اصلی ۱۴

۵ نتایج مدل‌سازی پیش‌بینی ۱۵

۵.۱ مقایسه‌ی مدل‌های مرحله‌ی الف ۱۵

۵.۲ نقاط کاری بازیابی‌محور ۱۵

۵.۳ آستانه‌ی تصمیم: اثر آن بر XGBoost ۱۶

۵.۴ ماتریس‌های درهم‌ریختگی ۱۷

۵.۵ اهمیت ویژگی‌ها ۱۸

۵.۶ تحلیل خطای زیرگروه‌ها ۱۹

۵.۷ مدل نهایی XGBoost در مرحله‌ی ب ۲۱

۶ یافته‌های کلیدی ۲۲

۷ تفسیر بالینی ۲۳

۷.۱ مصرف قبلی خدمات بستری ۲۳

۷.۲ مقصد ترخیص ۲۳

۷.۳ معنای عملی دقت ۲۳

۷.۴ کاربرد مدل به‌عنوان پشتیبان تصمیم ۲۴

۸ انصاف، قابلیت اتکا و عدم قطعیت ۲۴

۹ محدودیت‌ها ۲۵

۱۰ پیامدهای عملی ۲۵

۱۰.۱ استفاده برای اولویت‌بندی، نه خودکارسازی ۲۶

۱۰.۲ شرایطی که در آن نباید از مدل استفاده کرد ۲۶

۱۱ بازتولیدپذیری و محیط محاسباتی ۲۶

۱۲ نتیجه‌گیری ۲۷

الف تعداد دقیق خطاهای مدل‌ها ۲۸

ب ممیزی سازگاری و تفسیر ۲۸

پ واژه‌نامه‌ی اصطلاحات آماری ۲۹

فهرست شکل‌ها

۱ توزیع سه پیامد بستری مجدد در کل مجموعه‌داده. کلاس بستری مجدد زودهنگام پیامد اقلیت است. ۷

۲ هدف دودویی (بستری مجدد زودهنگام کمتر از ۳۰ روز در برابر سایر موارد) در کل مجموعه‌داده ($n = 101{,}766$)، هم‌گروه مدل‌سازی ($n = 99{,}343$) و مجموعه‌ی آزمون نگه‌داشته‌شده ($n = 19{,}948$). بستری مجدد زودهنگام در هر مرحله کلاس اقلیت است (۱۱/۱۶٪، ۱۱/۳۹٪ و ۱۱/۳۳٪). ۸

۳ توزیع سنیِ مراجعه‌های بیمارستانی در گروه‌های ده‌ساله. ۹

۴ نرخ بستری مجدد زودهنگام بر حسب گروه سنی. بیشتر گروه‌های بزرگسال در حدود ۱۰ تا ۱۲٪ قرار دارند؛ اوج ظاهری در سنین ۲۰ تا ۳۰ بر پایه‌ی زیرگروهی نسبتاً کوچک است. ۱۰

۵ بستری‌های قبلی بر حسب پیامد بستری مجدد. مراجعه‌های دارای بستری مجدد زودهنگام به سمت مصرف قبلی بیشتر خدمات بستری جابه‌جا شده‌اند. ۱۰

۶ مدت اقامت در بیمارستان بر حسب پیامد بستری مجدد. با وجود تفاوت اندک میانگین‌ها، توزیع‌ها هم‌پوشانی زیادی دارند. . . ۱۱

۷ مقادیر مطلق تفاوت‌های میانگین استانداردشده. مصرف قبلی خدمات بستری قوی‌ترین جداکننده‌ی عددی است. ۱۲

۸ ماتریس همبستگی پیرسون میان متغیرهای عددی مصرف خدمات. هیچ جفتی همبستگی خطی قوی نشان نمی‌دهد. ۱۲

۹ نرخ‌های خام بستری مجدد زودهنگام بر حسب نژاد. گروه‌های کوچک‌تر عدم قطعیتِ نمونه‌برداریِ وسیع‌تری دارند که در نمودار توصیفی نشان داده نشده است. ۱۴

۱۰ نرخ بستری مجدد زودهنگام بر حسب جنسیت. نرخ‌های خام بسیار شبیه هم‌اند. ۱۴

۱۱ نرخ بستری مجدد زودهنگام بر حسب گروه تشخیص اصلی. گروه بسیار کوچکِ «گمشده» نباید تفسیر شود. ۱۵

۱۲ XGBoost مرحله‌ی الف روی مجموعه‌ی آزمون نگه‌داشته‌شده: آستانه‌ی ۰/۴۱ تنظیم‌شده روی اعتبارسنجی در برابر آستانه‌ی پیش‌فرض ۰/۵۰. ROC-AUC و PR-AUC به آستانه وابسته نیستند؛ آستانه بازیابی را از ۰/۵۹۸ به ۰/۷۹۷ می‌رساند، به بهای کاهش دقت و صحت. ۱۶

۱۳ ماتریس‌های درهم‌ریختگی در آستانه‌های بازیابی‌محور. بازیابی بالا به بهای شمار زیادی هشدار مثبت کاذب به دست می‌آید. . ۱۸

۱۴ برترین ویژگی‌ها و ضرایب در چهار مدل مرحله‌ی الف. اهمیت نشان‌دهنده‌ی سهم در مدل است، نه اثر علّی. ۱۹

۱۵ تفاوت بیشینه و کمینه‌ی FNR درون زیرگروه‌های نژاد، جنسیت و سن. ۲۰

۱۶ نابرابری زیرگروه‌های سنی و پشتوانه‌ی آماری آن. چپ: شمار بستری‌های مجدد زودهنگام واقعی در هر گروه سنی در مجموعه‌ی آزمون (قرمز = کمتر از ۱۰). راست: شکاف FNR (بیشینه منهای کمینه) برای نژاد، جنسیت و سن در XGBoost مرحله‌ی الف با آستانه‌ی ۰/۴۱. . . . . ۲۱

۱۷ منحنی ROC برای مدل نهایی XGBoost. توان تفکیک گزارش‌شده متوسط است و ROC-AUC حدود ۰/۶۸ است. . . ۲۲

فهرست جدول‌ها

۱ جامعه‌ی مورد مطالعه و مراحل تحلیلی. ۳
۲ ممیزی کیفیت داده و تصمیم‌های آماده‌سازی. ۴
۳ روش‌های آماری به‌کاررفته و دلیل انتخاب آن‌ها. ۵
۴ پیکربندی مدل‌های مرحله‌ی الف. ۶
۵ نگاشت دسته‌های اصلی بستری مجدد به هدف دودویی. ۸
۶ نرخ بستری مجدد زودهنگام بر حسب گروه سنی. ۹
۷ مقادیر مطلق تفاوت میانگین استانداردشده میان بستری مجدد زودهنگام و سایر مراجعه‌ها. ۱۱
۸ ضریب V کرامر برای متغیرهای طبقه‌ای منتخب و بستری مجدد زودهنگام. ۱۳
۹ نرخ بستری مجدد زودهنگام بر حسب نژاد. ۱۳
۱۰ عملکرد مدل‌های مرحله‌ی الف در آستانه‌ی احتمال پیش‌فرض ۰/۵۰. . . . . ۱۵
۱۱ عملکرد مرحله‌ی الف در آستانه‌های انتخاب‌شده با F_2 روی مجموعه‌ی اعتبارسنجی. ۱۶
۱۲ اثر آستانه‌ی تصمیم بر XGBoost مرحله‌ی الف (مجموعه‌ی آزمون نگه‌داشته‌شده). مقادیر علامت‌دار با † از بازیابی، دقت و اندازه‌ی مجموعه‌ی آزمونِ گزارش‌شده استخراج شده‌اند. ۱۷
۱۳ پیش‌بینی‌کننده‌های پیشرو بر حسب مدل. ۱۸
۱۴ شکاف FNR زیرگروه‌ها در مرحله‌ی الف در آستانه‌های بازیابی‌محور. ۱۹
۱۵ مجموعه‌ی آزمون نگه‌داشته‌شده: مراجعه‌ها و بستری‌های مجدد زودهنگام واقعی (موارد مثبت) در هر گروه سنی. با اجرای دوباره‌ی تقسیم گروهی با `random_state=123` استخراج شده است؛ مجموع‌ها با دفترچه‌ی تحلیل مطابقت دارند. ۲۰
۱۶ مدل نهایی XGBoost با ابرپارامترهای جست‌وجوشده روی مجموعه‌ی آزمون نگه‌داشته‌شده. ۲۲
۱۷ محیط محاسباتی و اجزای تحلیلی. ۲۶
۱۸ تعداد خطاها در آستانه‌های بازیابی‌محور مرحله‌ی الف. ۲۸
۱۹ تمایزهای تحلیلیِ کلیدی که در این دست‌نوشته حفظ شده‌اند. ۲۸
۲۰ ممیزی سازگاریِ دفترچه‌ی منبع. ۲۹
۲۱ واژه‌نامه‌ی اصطلاحات آماری (انگلیسی به فارسی). ۳۰

۱ مقدمه

بستری مجدد بیمارستانی پیامدی مهم از نظر بالینی و عملیاتی است، زیرا ترکیبی از بار بیماری، سابقه‌ی استفاده از خدمات درمانی، شرایط ترخیص، تداوم مراقبت و سیر طبیعی بیماری مزمن را بازتاب می‌دهد. در بیماران مبتلا به دیابت، این عوامل می‌توانند با بیماری‌های همراه متعدد، تغییرات دارویی، عوارض حاد و مواجهه‌ی مکرر با خدمات بستری و اورژانس برهم‌کنش داشته باشند. در نتیجه، یک مراجعه‌ی اداری بیمارستانی ممکن است تنها یک مشاهده در الگویی طولی از مراقبت باشد.

پژوهش حاضر مسئله‌ی شناسایی مراجعه‌های بیمارستانی را بررسی می‌کند که ظرف ۳۰ روز با بستری مجدد دنبال شده‌اند. تحلیل بر پایه‌ی مجموعه‌داده‌ی «دیابت، ۱۳۰ بیمارستان آمریکا» انجام شده است که حدود صد هزار مراجعه‌ی بیمارستانی بیماران مبتلا به دیابت را در چندین بیمارستان آمریکا طی سال‌های ۱۹۹۹ تا ۲۰۰۸ در بر می‌گیرد. این مجموعه‌داده برای کارهای روش‌شناختی به‌ویژه سودمند است، زیرا متغیرهای بالینی و اداری را با هم دارد، شامل مراجعه‌های مکرر یک بیمار است، مقادیر گمشده‌ی قابل‌توجهی دارد و پیامد بستری مجدد زودهنگام در آن به‌شدت نامتوازن است.

چالش روش‌شناختی اصلی این است که اگر مراجعه‌های مکرر یک بیمار به‌صورت تصادفی میان مجموعه‌ی آموزش و آزمون تقسیم شوند، نشت اطلاعات رخ می‌دهد. در این حالت، مدل ممکن است خوب تعمیم‌پذیر به نظر برسد، در حالی که بخشی از آن صرفاً الگوهای اختصاصی بیمار را می‌شناسد که در هر دو بخش حضور دارند. بنابراین این پژوهش از تقسیم‌بندی گروهی بر اساس بیمار و اعتبارسنجی متقاطع گروهی استفاده می‌کند. هدف، صرفاً بیشینه‌کردن یک معیار متعارف صحت نیست؛ بلکه بررسی این است که آیا مدل‌ها می‌توانند نسبت معناداری از موارد بستری مجدد زودهنگام را شناسایی کنند، در حالی که مصالحه‌ی میان بازیابی و دقت به‌روشنی نشان داده می‌شود.

این کار چهار هدف مکمل دارد:

۱. توصیف توزیع بستری مجدد ظرف ۳۰ روز و الگوهای مهم استفاده‌ی قبلی از خدمات؛
۲. کمّی‌سازی تفاوت‌ها با اندازه‌های اثرِ تفسیرپذیر، به‌جای تکیه‌ی صرف بر معناداری آماری؛
۳. مقایسه‌ی چهار الگوریتم طبقه‌بندی تحت کنترل نشت در سطح بیمار و عدم توازن کلاس‌ها؛
۴. بررسی الگوهای خطا در زیرگروه‌ها و برگرداندن یافته‌ها به پیامدهای محتاطانه و بالینی‌مرتبط برای پشتیبانی از تصمیم.

تمایز میان ارتباط و علیت در سراسر متن حفظ شده است. ویژگی‌ای که ارتباط قوی با بستری مجدد دارد لزوماً علتِ قابل‌مداخله‌ی بستری مجدد نیست، و اهمیت یک ویژگی در مدل، شاهدی بر علیت بالینی نیست.

۲ زمینه‌ی بالینی و تحلیلی

۲.۱ بستری مجدد ظرف ۳۰ روز به‌عنوان یک پیامد پزشکی

بستری مجدد ظرف ۳۰ روز معمولاً به‌عنوان پیامدی کوتاه‌افق برای ارزیابی فرایندهای مراقبت پس از ترخیص و شناسایی بیمارانی به کار می‌رود که ممکن است به پیگیری نزدیک‌تر نیاز داشته باشند. در بیماری‌های مزمن مانند دیابت، بستری مجدد می‌تواند ناشی از عوارض عودکننده‌ی بیماری، بیماری‌های همراه، برنامه‌ریزی ناکافی برای انتقال مراقبت، مشکلات دارویی یا رویدادهای حاد نامرتبط باشد. از آنجا که مجموعه‌داده‌ی حاضر مشاهده‌ای و اداری است، این تحلیل تلاشی برای نسبت‌دادن هر بستری مجدد به سازوکار بالینی مشخص نمی‌کند.

هدف (متغیر پاسخ) به این صورت تعریف می‌شود:

$$Y = \begin{cases} 1, & \text{اگر مراجعه ظرف ۳۰ روز با بستری مجدد دنبال شود،} \\ 0, & \text{در غیر این صورت.} \end{cases}$$

بنابراین پیامد سه‌سطحی اصلی (<30، >30 و NO) برای مدل‌سازی به یک پیامد دودویی تبدیل می‌شود. این صورت‌بندی مستقیماً پرسش بالینی «عود زودهنگام پس از ترخیص» را بازتاب می‌دهد.

۲.۲ چرا عدم توازن کلاس‌ها اهمیت دارد

تنها ٪۱۱/۱۶ از کل مجموعه‌داده به کلاس بستری مجدد زودهنگام تعلق دارد. طبقه‌بندی‌ای که همه‌ی مراجعه‌ها را منفی برچسب بزند، صحتی ظاهری در حدود ٪۸۸/۸۴ خواهد داشت، در حالی که هیچ‌یک از بیمارانی را که دچار بستری مجدد زودهنگام می‌شوند شناسایی نکرده است. از این رو صحت (Accuracy) در این زمینه معیار سرخط مناسبی نیست.

برای یک طبقه‌بند دودویی، کمیت‌های اصلی عبارت‌اند از بازیابی (Recall) و دقت (Precision):

$$\text{Recall} = \frac{TP}{TP + FN}, \qquad \text{Precision} = \frac{TP}{TP + FP},$$

و امتیاز F_1:

$$F_1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}.$$

هنگامی که از دست رفتن یک رویداد واقعی پرهزینه‌تر از تولید یک هشدار اضافی تلقی شود، می‌توان از معیار F_β با $\beta > 1$ استفاده کرد:

$$F_\beta = (1 + \beta^2)\frac{\text{Precision} \times \text{Recall}}{\beta^2\,\text{Precision} + \text{Recall}}.$$

این پژوهش $\beta = 2$ را به کار می‌برد، که نتیجه می‌دهد:

$$F_2 = 5\,\frac{\text{Precision} \times \text{Recall}}{4\,\text{Precision} + \text{Recall}}.$$

۲.۳ توان تفکیک و رتبه‌بندی

مساحت زیر منحنی ROC (ROC-AUC) توانایی مدل را در رتبه‌بندی مراجعه‌های مثبت بالاتر از مراجعه‌های منفی، در تمام آستانه‌های ممکن خلاصه می‌کند. تحلیل دقت-بازیابی (Precision-Recall) وقتی کلاس مثبت نادر است، به‌ویژه آگاهی‌بخش است. بنابراین مساحت زیر منحنی دقت-بازیابی (PR-AUC) مکمل ROC-AUC است و کمک می‌کند معلوم شود مدل در شیوع پایین کلاس مثبت چقدر کارآمد می‌ماند.

نرخ منفی کاذب (FNR) برابر است با:

$$\text{FNR} = \frac{FN}{FN + TP} = 1 - \text{Recall}.$$

در کاربرد اولویت‌بندی (تریاژ) بالینی، FNR از نظر عملیاتی اهمیت دارد، زیرا یک منفی کاذب به مراجعه‌ای از نوع بستری مجدد زودهنگام اشاره دارد که مدل آن را علامت‌گذاری نکرده است.

۳ مواد و روش‌ها

۳.۱ منبع داده و هم‌گروه مطالعه

این پروژه از مجموعه‌داده‌ی «دیابت، ۱۳۰ بیمارستان آمریکا، سال‌های ۱۹۹۹ تا ۲۰۰۸» استفاده می‌کند. مجموعه‌داده‌ی اصلی شامل ۱۰۱,۷۶۶ مراجعه و ۷۱,۵۱۸ بیمار یکتا است و پس از پیش‌پردازش و بازبینی کیفیت داده در پروژه، ۵۰ متغیر دارد. داده‌ها نمایانگر مراجعه‌های بیمارستانی‌اند، نه افراد مستقل: ۵۴,۷۴۵ بیمار فقط یک مراجعه دارند، ۱۶,۷۷۳ بیمار بیش از یک مراجعه دارند و بیشینه‌ی تعداد مراجعه برای یک بیمار ۴۰ است. این تمایز در برآورد عملکرد مدل ضروری است.

پروژه یک مجموعه‌داده‌ی اکتشافیِ هم‌گروه کامل را برای تحلیل توصیفی نگه داشت. برای پیش‌بینی، ۲,۴۲۳ مراجعه‌ی منجر به فوت/هاسپیس حذف شد و ۹۹,۳۴۳ مراجعه باقی ماند. این حذف انجام شد زیرا شرایط ترخیص مربوط به آن‌ها مسئله‌ی متعارف ریسک بستری مجدد پس از ترخیص را نمایندگی نمی‌کند، و نیز به این دلیل که نشانگر `death_or_hospice` پس از این محدودسازی ثابت می‌شد.

جدول ۱: جامعه‌ی مورد مطالعه و مراحل تحلیلی.

مرحله	مراجعه‌ها	بستری مجدد زودهنگام	هدف
کل مجموعه‌داده	۱۰۱,۷۶۶	۱۱,۳۵۷ (۱۱/۱۶٪)	تحلیل اکتشافی و آمار توصیفی
هم‌گروه بدون فوت/هاسپیس	۹۹,۳۴۳	۱۱/۳۹٪	مدل‌سازی پیش‌بینی
مجموعه‌ی آموزش	۷۹,۳۹۵	—	برازش مدل
مجموعه‌ی آزمون نگه‌داشته‌شده	۱۹,۹۴۸	۲,۲۶۰ (۱۱/۳۳٪)	ارزیابی نهایی عملکرد

۳.۲ کیفیت داده و پیش‌پردازش

پروژه بررسی داده‌های تکراری، مقادیر گمشده، غربالگری متغیرهای ثابت، بازکدگذاری متغیرهای طبقه‌ای، استانداردسازی عددی و غربالگری داده‌های پرت را مستند کرده است. داده‌ها در متغیرهایی مانند `weight`، `payer_code` و `medical_specialty` مقادیر گمشده‌ی قابل‌توجهی دارند. فیلد `weight` حدود ۹۶/۸۶٪ گمشده است و به‌عنوان اندازه‌گیری پیوسته‌ی قابل‌اعتماد در نظر گرفته نشد.

خط لوله‌ی پیش‌پردازش برای متغیرهای عددی از جای‌گذاری با میانه، و برای متغیرهای طبقه‌ای از پرتکرارترین مقدار یا یک دسته‌ی صریح «Missing» استفاده می‌کند. متغیرهای عددی در مواردی که مدل لازم دارد استانداردسازی می‌شوند. متغیرهای طبقه‌ای درون یک خط لوله‌ی مدل‌سازی با روش یک‌داغ (one-hot) کدگذاری می‌شوند تا تبدیل‌ها فقط از داده‌ی آموزش برآورد شوند.

دو محدودیت مهم پنهان نشد و نگه داشته شد. نخست، شناسه‌های اداری مانند `admission_type_id`، `discharge_disposition_id` و `admission_source_id` علاوه بر نسخه‌های کدگذاری‌شده‌ی طبقه‌ای‌شان، به‌طور خودکار عددی نیز در نظر گرفته شدند. دوم، ستون‌های خام تشخیص `diag_1` تا `diag_3` در کنار دسته‌های گروه‌بندی‌شده‌ی تشخیص باقی ماندند و فضای ویژگی یک‌داغِ بسیار پهنی ایجاد کردند. این انتخاب‌ها منابع بالقوه‌ی نوفه‌اند و به همین دلیل به‌عنوان محدودیت بحث می‌شوند و به‌عنوان سازوکار بالینی تفسیر نمی‌شوند.

جدول ۲: ممیزی کیفیت داده و تصمیم‌های آماده‌سازی.

گام	نتیجه / تصمیم
بارگذاری	۱۰۱,۷۶۶ سطر × ۵۰ ستون؛ فایل‌ها با `keep_default_na=False` خوانده شدند تا رشته‌ی لفظی `None` در `A1Cresult` و `max_glu_serum` به‌عنوان یک دسته‌ی معتبر حفظ شود؛ علامت `?` به‌عنوان نشانگر مقدار گمشده در نظر گرفته شد
مراجعه‌های تکراری	۰ شناسه‌ی مراجعه‌ی تکراری و ۰ سطر کاملاً تکراری؛ هیچ سطری حذف نشد
مراجعه‌های مکرر	۱۶,۷۷۳ بیمار با چند مراجعه حفظ شدند؛ شناسه‌ی بیمار برای تقسیم‌بندی گروهی به کار رفت
مقادیر گمشده	`weight`: ٪۹۶/۸۶ (کنار گذاشته شد)؛ `medical_specialty`: ٪۴۹/۰۸؛ `payer_code`: ٪۳۹/۵۶؛ `race`: ٪۲/۲۳؛ `diag_3`: ٪۱/۴۰؛ `diag_2`: ٪۰/۳۵؛ `diag_1`: ٪۰/۰۲. موارد اخیر به یک دسته‌ی صریح Missing بازکدگذاری شدند؛ هیچ سطری حذف نشد. سه مقدار جنسیتِ نامشخص/نامعتبر نیز به Missing بازکدگذاری شد
ویژگی‌های ثابت	`examide` و `citoglipton` فقط یک مقدار یکتا دارند و کنار گذاشته شدند
غربالگری داده‌های پرت	حصارهای $\text{IQR}1.5\times$ مقادیر زیادی را علامت می‌زنند (٪۱۶/۴۵ از `number_outpatient` و ٪۱۱/۱۹ از `number_emergency`)، اما این متغیرها صفر-متورم‌اند (به‌ترتیب ٪۸۳/۵۵ و ٪۸۸/۸۱ صفر)؛ IQR فقط ابزار غربالگری بود و هیچ مشاهده‌ای حذف نشد
نگاشت کدها	`admission_type_id`، `admission_source_id` و `discharge_disposition_id` به برچسب‌های خوانا نگاشت شدند؛ ۰ مقدار نگاشت‌نشده
مهندسی ویژگی	متغیر هدف دودویی `early_readmission`؛ نشانگر `death_or_hospice` از شناسه‌های ترخیص ۱۱، ۱۳، ۱۴، ۱۹، ۲۰ و ۲۱ (۲,۴۲۳ مراجعه، ٪۲/۳۸)؛ گروه‌بندی ICD-9 متغیرهای `diag_1` تا `diag_3` در ده دسته‌ی کلی (گردش خون، تنفسی، گوارشی، دیابت، آسیب، اسکلتی‌عضلانی، ادراری‌تناسلی، نئوپلاسم‌ها، سایر و گمشده)
پیش‌بینی‌کننده‌ها	۵۱ ستون پیش‌بینی‌کننده (۱۱ عددی، ۴۰ طبقه‌ای). نژاد، جنسیت و سن به‌عنوان پیش‌بینی‌کننده نگه داشته شدند و برای ارزیابی زیرگروه‌ها به کار رفتند. از پیش‌بینی‌کننده‌ها کنار گذاشته شدند: شناسه‌ها، نشانگر بیمار تکراری، ستون‌های پیامد، `weight` و دو ویژگی ثابت

شمار مراجعه‌های با مصرف خدمات بسیار زیاد (برای نمونه تا ۷۶ مراجعه‌ی اورژانس و ۴۲ مراجعه‌ی سرپایی در دوره‌ی پیشین برای یک مراجعه) وجود دارد که حفظ شدند، زیرا ممکن است بیمارانِ واقعاً پرمصرف را نمایندگی کنند. افزون بر این، ۳,۶۹۱ مراجعه (٪۳/۶۳) مقصد ترخیص گمشده دارند و ۵,۲۹۱ نوع پذیرش با مقدار `NULL` کدگذاری شده است.

گام‌های زیر انجام **نشد**، زیرا فایل‌های پروژه از آن‌ها پشتیبانی نمی‌کنند: نمونه‌برداری مجدد (SMOTE یا کم‌نمونه‌گیری)، انتخاب ویژگی رسمی، تبدیل‌های لگاریتمی یا توانی، تجمیع ستون‌های دارویی، پالایش هم‌خطی و جای‌گذاری فراتر از میانه/پرتکرارترین مقدار.

۳.۳ تحلیل آماری اکتشافی

تحلیل اکتشافی بر اندازه‌های اثر و مقایسه‌های توصیفیِ شفاف تأکید دارد.

۳.۳.۱ تفاوت میانگین استانداردشده

برای متغیر عددی X، تفاوت میانگین استانداردشده میان مراجعه‌های دارای بستری مجدد زودهنگام و سایر مراجعه‌ها چنین است:

$$\text{SMD} = \frac{\bar{X}_1 - \bar{X}_0}{\sqrt{\frac{1}{2}(s_1^2 + s_0^2)}}.$$

این کمیتِ بدون واحد امکان مقایسه‌ی متغیرهای با مقیاس‌های متفاوت را فراهم می‌کند. مقادیر مطلق SMD در حدود ۰/۲، ۰/۵ و ۰/۸ در راهنماهای روش‌شناختی عمومی اغلب به‌ترتیب کوچک، متوسط و بزرگ توصیف می‌شوند، هرچند این آستانه‌ها قانون بالینی نیستند.

۳.۳.۲ ضریب V کرامر

برای متغیرهای طبقه‌ای، ارتباط با پیامد دودویی با ضریب V کرامر خلاصه شد:

$$V = \sqrt{\frac{\chi^2/n}{\min(r-1, k-1)}},$$

که در آن n حجم نمونه و r و k به‌ترتیب تعداد سطرها و ستون‌های جدول پیشامد هستند.

۳.۳.۳ همبستگی و غربالگری داده‌های پرت

همبستگی پیرسون به‌عنوان ابزار غربالگری توصیفی برای روابط میان متغیرهای عددیِ مصرف خدمات به کار رفت. مقادیر فرین با حصارهای متعارف دامنه‌ی بین‌چارکی (IQR) غربال شدند:

$$[Q_1 - 1.5\,\mathrm{IQR},\ Q_3 + 1.5\,\mathrm{IQR}], \qquad \mathrm{IQR} = Q_3 - Q_1.$$

مقادیر فرینِ مصرف خدمات در صورتی که می‌توانستند بیماران واقعاً پرمصرف را نمایندگی کنند، حفظ شدند.

۳.۳.۴ دامنه‌ی استنباط آماری

دفترچه‌ی تحلیل به‌جای آزمون‌های فرضِ رسمی، به آماره‌های توصیفیِ مبتنی بر اندازه‌ی اثر تکیه دارد؛ **هیچ مقدار pای در هیچ‌جای تحلیل گزارش نشده است و در اینجا نیز چیزی اضافه نشده است.** چون تحلیل اکتشافی است، فرضیه‌ها به‌طور رسمی بیان نشدند و سطح معناداری‌ای اعمال نمی‌شود. آماره‌ی خی‌دو درون تابع V کرامر محاسبه می‌شود اما نمایش داده نمی‌شود. با حدود ۱۰۰,۰۰۰ مراجعه، اندازه‌های اثر انتخاب مناسبی‌اند، زیرا حتی تفاوت‌های ناچیز نیز مقدار pهای بسیار کوچکی به دست می‌دهند؛ اندازه‌های اثر نشان می‌دهند که آیا تفاوت آن‌قدر بزرگ هست که اهمیت داشته باشد.

جدول ۳: روش‌های آماری به‌کاررفته و دلیل انتخاب آن‌ها.

روش	هدف	دلیل انتخاب
تفاوت میانگین استانداردشده	مقایسه‌ی متغیرهای عددی میان بستری مجدد زودهنگام و سایر مراجعه‌ها	اندازه‌ی اثرِ بدون واحد که صرف‌نظر از حجم نمونه آگاهی‌بخش است
ضریب V کرامر	ارتباط یک متغیر طبقه‌ای با پیامد دودویی	متغیرهای با تعداد سطوح متفاوت را مدیریت می‌کند؛ بین ۰ و ۱ کراندار است
همبستگی پیرسون	روابط میان متغیرهای عددی	غربالگری ساده‌ی ارتباط خطی و افزونگی
قاعده‌ی $1.5\times$ IQR	غربالگری مقادیر فرین	ابزار غربالگری است، نه قاعده‌ی حذف خودکار
نرخ‌های گروهی همراه با شمارش‌ها	مقایسه‌ی درصدهای بستری مجدد زودهنگام میان گروه‌ها	شفاف است؛ اندازه‌ی نمونه‌ها نشان داده می‌شود تا گروه‌های کوچک بیش‌ازحد تفسیر نشوند

مقدار $\mathrm{SMD} = 0.415$ بر اساس قواعد سرانگشتیِ رایج (۰/۲ کوچک، ۰/۵ متوسط) تفاوتی کوچک تا متوسط است؛ قوی‌ترین سیگنال عددی است ولی همچنان هم‌پوشانی زیادی میان دو گروه باقی می‌گذارد. همه‌ی مقادیر V کرامر کوچک‌اند (بزرگ‌ترین آن‌ها ۰/۱۲۵ است) و ارتباط‌هایی که از نظر آماری قابل‌تشخیص‌اند لزوماً از نظر عملی مفید نیستند. داده‌ها مشاهده‌ای‌اند و هیچ طرح علّی به کار نرفته است. یک توسعه‌ی طبیعی که در اینجا انجام نشد، آزمون‌های خی‌دو و مان–ویتنی (یا رگرسیون لجستیک) همراه با بازه‌های اطمینان و تصحیح مقایسه‌های چندگانه است.

۳.۴ کنترل نشت در سطح بیمار

شناسه‌ی بیمار `patient_nbr` فقط برای گروه‌بندی به کار رفت و به‌عنوان ویژگی پیش‌بینی‌کننده وارد نشد. یک تقسیم ۸۰/۲۰ با GroupShuffleSplit و `random_state=123` نتایج زیر را داد:

- آموزش: ۷۹,۳۹۵ مراجعه و ۵۵,۹۹۲ بیمار؛
- آزمون: ۱۹,۹۴۸ مراجعه و ۱۳,۹۹۸ بیمار؛

- هم‌پوشانی بیماران: صفر.

این یک پادمان حیاتی است، چون یک بیمار می‌تواند چند مراجعه‌ی بیمارستانی داشته باشد. طرح مدل‌سازی بدین‌ترتیب تعمیم‌پذیری به بیمارانی را برآورد می‌کند که در بخش آموزش حضور نداشته‌اند.

۳.۵ مدل‌های یادگیری ماشین

چهار الگوریتم مقایسه شدند:

۱. رگرسیون لجستیک به‌عنوان یک مبنای خطی شفاف؛
۲. درخت تصمیم به‌عنوان مدلی غیرخطی و تفسیرپذیر؛
۳. جنگل تصادفی به‌عنوان مجموعه‌ای از درخت‌های تصمیم؛
۴. XGBoost به‌عنوان مجموعه‌ی درخت‌های تقویت‌شده‌ی گرادیانی.

عدم توازن کلاس‌ها با وزن‌دهی کلاس برای رگرسیون لجستیک و درخت تصمیم، زیرنمونه‌گیری متوازن برای جنگل تصادفی، و نسبت وزن کلاس مثبت برای XGBoost مدیریت شد.

جدول ٤: پیکربندی مدل‌های مرحله‌ی الف.

مدل	تنظیمات اصلی
رگرسیون لجستیک	`max_iter=2000`؛ وزن‌های کلاس متوازن
درخت تصمیم	`max_depth=8`؛ `min_samples_leaf=50`؛ وزن‌های کلاس متوازن
جنگل تصادفی	۲۵۰ درخت؛ `max_depth=16`؛ `min_samples_leaf=10`؛ زیرنمونه‌گیری متوازن
XGBoost	۲۵۰ درخت؛ عمق ۵؛ نرخ یادگیری ۰/۰۵؛ `min_child_weight=5`؛ زیرنمونه ۰/۸؛ زیرنمونه‌ی ستونی ۰/۸؛ تنظیم‌سازی ۱/۰

۳.۶ بهینه‌سازی آستانه

آستانه‌ی احتمال پیش‌فرض ۰/۵۰ وقتی هدف بالینی بر حساسیت تأکید دارد، لزوماً مناسب نیست. بنابراین از یک تقسیم اعتبارسنجی درون داده‌ی آموزش برای جست‌وجوی آستانه‌ها از ۰/۰۵ تا ۰/۵۰ با گام ۰/۰۱ استفاده شد. آستانه‌ای که F_2 را بیشینه می‌کرد، برای هر مدل مرحله‌ی الف انتخاب شد. مجموعه‌ی آزمون نگه‌داشته‌شده در طول این انتخاب دست‌نخورده ماند.

جست‌وجوی آستانه یک نقطه‌ی کاری صریح و مبتنی بر مصالحه می‌سازد: پایین‌آوردن آستانه شمار مراجعه‌های علامت‌گذاری‌شده را افزایش می‌دهد و عموماً بازیابی را بالا و دقت را پایین می‌برد. این مصالحه برای تفسیر مدل به‌عنوان ابزار اولویت‌بندی، و نه یک ابزار تشخیصی خودمختار، محوری است.

۳.۷ جست‌وجوی ابرپارامتر

یک مدل XGBoost مرحله‌ی دوم از `RandomizedSearchCV` با ۱۲ ترکیب نمونه‌برداری‌شده از پارامترها و اعتبارسنجی سه‌بخشیِ `StratifiedGroupKFold` گروه‌بندی‌شده بر اساس بیمار استفاده کرد. معیار بهینه‌سازی F_2 بود. بهترین مجموعه‌ی پارامترها چنین بود:

$$n_{\text{estimators}} = 200, \quad \text{max_depth} = 3, \quad \text{learning rate} = 0.05,$$

$$\text{min_child weight} = 5, \quad \text{subsample} = 0.8, \quad \text{colsample_bytree} = 1.0, \quad \lambda = 1.0.$$

بهترین F_2 اعتبارسنجی‌متقاطع برابر ۰/۴۰۶ بود.

۳.۸ تحلیل زیرگروه‌ها

تحلیل با رویکرد انصاف بر بازیابی و FNR درون گروه‌های نژاد، جنسیت و سن متمرکز بود. برای هر مدل:

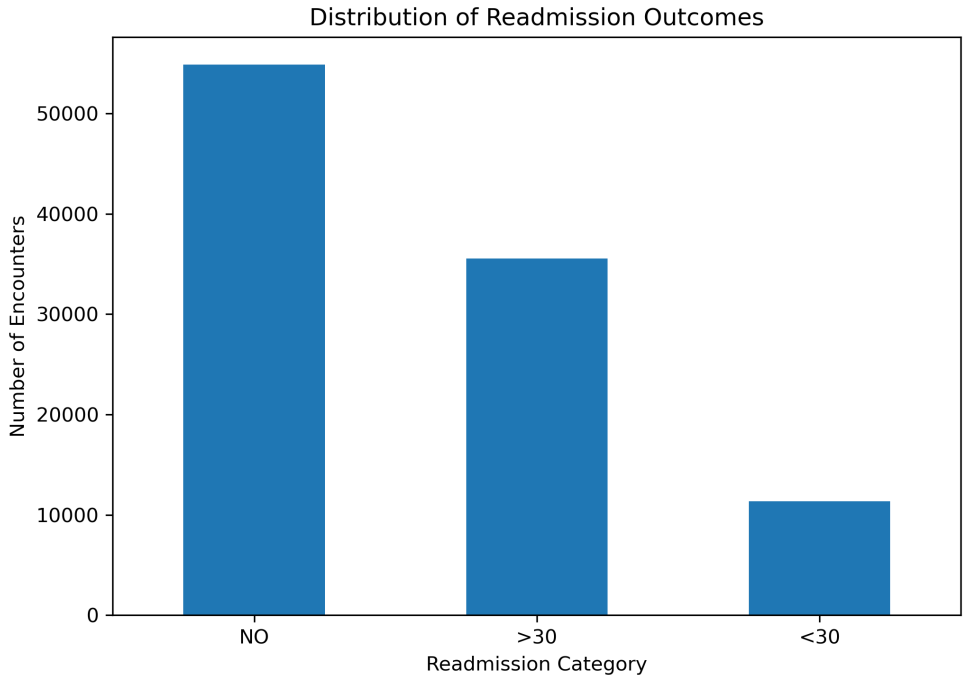
$$\text{FNR gap} = \max_g(\text{FNR}_g) - \min_g(\text{FNR}_g).$$

این برآوردها همراه با اندازه‌ی نمونه‌ی زیرگروه‌ها تفسیر شدند. به‌ویژه، FNR برابر ۱/۰ در گروهی که تنها یک مورد مثبت دارد، همان قدرت شواهد را ندارد که FNR برآوردشده از صدها مورد مثبت دارد.

۴ یافته‌ها

۴.۱ توزیع پیامد بستری مجدد

توزیع پیامد سه‌سطحی به‌شدت نامتوازن است. از ۱۰۱,۷۶۶ مراجعه، ۱۱,۳۵۷ مورد (۱۱/۱۶٪) ظرف ۳۰ روز با بستری مجدد دنبال شدند، ۳۴/۹۳٪ پس از ۳۰ روز بستری مجدد شدند و ۵۳/۹۱٪ بستری مجدد نشدند.



شکل ۱: توزیع سه پیامد بستری مجدد در کل مجموعه‌داده. کلاس بستری مجدد زودهنگام پیامد اقلیت است.

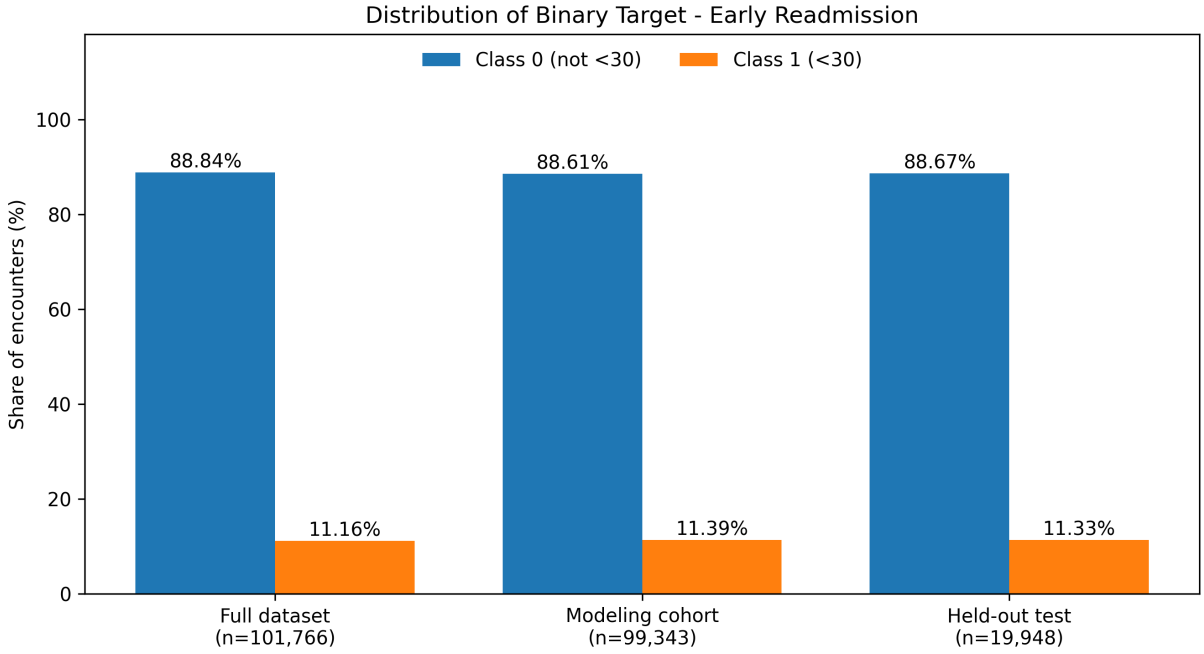
عدم توازن نشان‌داده‌شده در شکل ۱ توضیح می‌دهد که چرا صحت را نمی‌توان تنها معیار عملکرد دانست. پرسش بالینی دقیقاً این است که آیا موارد اقلیتِ بستری مجدد زودهنگام را می‌توان با بار هشدار کاذبِ قابل‌قبول شناسایی کرد.

۴.۲ توزیع هدف دودویی

چون مسئله‌ی مدل‌سازی دودویی است، سه دسته‌ی اصلی ادغام شدند: NO و 30 $>$ کلاس ۰ (بدون بستری مجدد زودهنگام) و 30 $<$ کلاس ۱ را می‌سازند. شکل ۲ توازن کلاس‌ها را در سه مرحله‌ی تحلیل نشان می‌دهد.

جدول ۵: نگاشت دسته‌های اصلی بستری مجدد به هدف دودویی.

دسته‌ی اصلی	مراجعه‌ها	هدف دودویی
< 30	۱۱,۳۵۷ (۱۱/۱۶٪)	۱ (بستری مجدد زودهنگام)
> 30	۳۵,۵۴۵ (۳۴/۹۳٪)	۰
NO	۵۴,۸۶۴ (۵۳/۹۱٪)	۰
مجموع کلاس ۰	۹۰,۴۰۹ (۸۸/۸۴٪)	۰

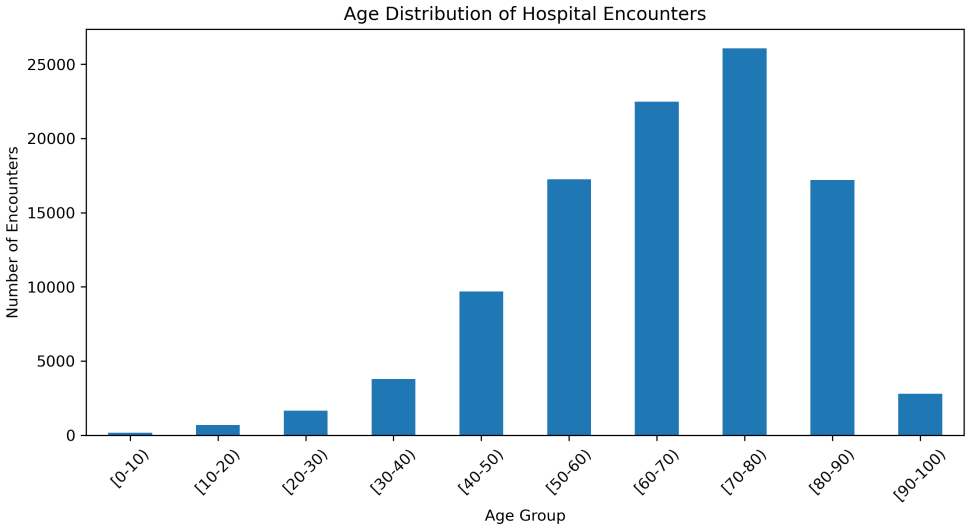


شکل ۲: هدف دودویی (بستری مجدد زودهنگام کمتر از ۳۰ روز در برابر سایر موارد) در کل مجموعه‌داده ($n = 101{,}766$)، هم‌گروه مدل‌سازی ($n = 99{,}343$) و مجموعه‌ی آزمون نگه‌داشته‌شده ($n = 19{,}948$). بستری مجدد زودهنگام در هر مرحله کلاس اقلیت است (۱۱/۱۶٪، ۱۱/۳۹٪ و ۱۱/۳۳٪).

بستری مجدد زودهنگام در هر مرحله پیامد اقلیت است. طبقه‌بندی‌ای که برای هر مراجعه «بدون بستری مجدد زودهنگام» پیش‌بینی کند حدود ۸۹٪ مواقع درست خواهد بود، در حالی که از نظر بالینی بی‌فایده است؛ به همین دلیل صحت معیار اصلی نیست. توزیع سه‌دسته‌ای اصلی (شکل ۱) صرفاً توصیفی است و هدف مدل‌سازی نیست.

۴.۳ توزیع سنی

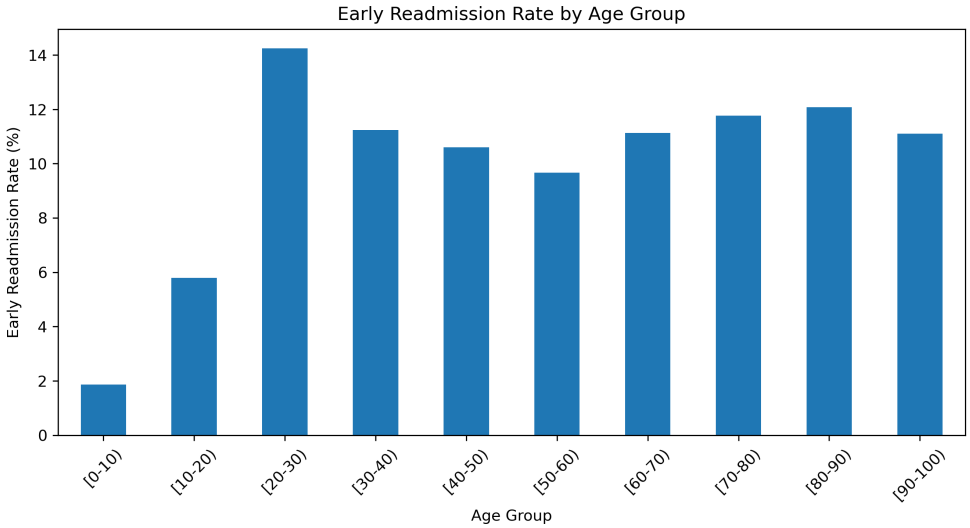
هم‌گروه در سالمندان متمرکز است. بزرگ‌ترین گروه ده‌ساله ۷۰ تا ۸۰ سال با ۲۶,۰۶۸ مراجعه است، پس از آن ۶۰ تا ۷۰ سال با ۲۲,۴۸۳ و ۸۰ تا ۹۰ سال با ۱۷,۱۹۷ مراجعه قرار دارند.



شکل ۳: توزیع سنیِ مراجعه‌های بیمارستانی در گروه‌های ده‌ساله.

جدول ٦: نرخ بستری مجدد زودهنگام بر حسب گروه سنی.

گروه سنی	مراجعه‌ها	بستری‌های مجدد زودهنگام	نرخ
[0–10)	۱۶۱	۳	۱/۸۶٪
[10–20)	۶۹۱	۴۰	۵/۷۹٪
[20–30)	۱,۶۵۷	۲۳۶	۱۴/۲۴٪
[30–40)	۳,۷۷۵	۴۲۴	۱۱/۲۳٪
[40–50)	۹,۶۸۵	۱,۰۲۷	۱۰/۶۰٪
[50–60)	۱۷,۲۵۶	۱,۶۶۸	۹/۶۷٪
[60–70)	۲۲,۴۸۳	۲,۵۰۲	۱۱/۱۳٪
[70–80)	۲۶,۰۶۸	۳,۰۶۹	۱۱/۷۷٪
[80–90)	۱۷,۱۹۷	۲,۰۷۸	۱۲/۰۸٪
[90–100)	۲,۷۹۳	۳۱۰	۱۱/۱۰٪

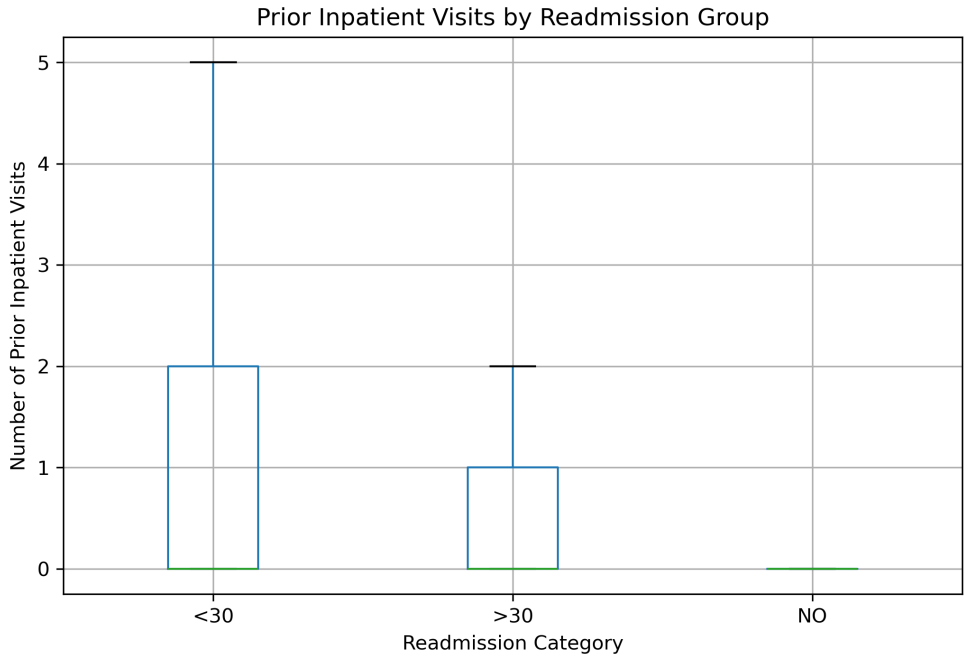


شکل ٤: نرخ بستری مجدد زودهنگام بر حسب گروه سنی. بیشتر گروه‌های بزرگسال در حدود ۱۰ تا ٪۱۲ قرار دارند؛ اوج ظاهری در سنین ۲۰ تا ۳۰ بر پایه‌ی زیرگروهی نسبتاً کوچک است.

شباهت گسترده‌ی نرخ‌ها در بزرگسالان نشان می‌دهد که سن به‌تنهایی در این مجموعه‌داده جداکننده‌ی توصیفیِ قوی نیست. درصد نسبتاً بالا در گروه ۲۰ تا ۳۰ سال نباید اثر سن تفسیر شود، زیرا مخرج آن بسیار کوچک‌تر از گروه‌های مسن‌تر است.

۴.۴ مصرف قبلی خدمات و طول مدت اقامت

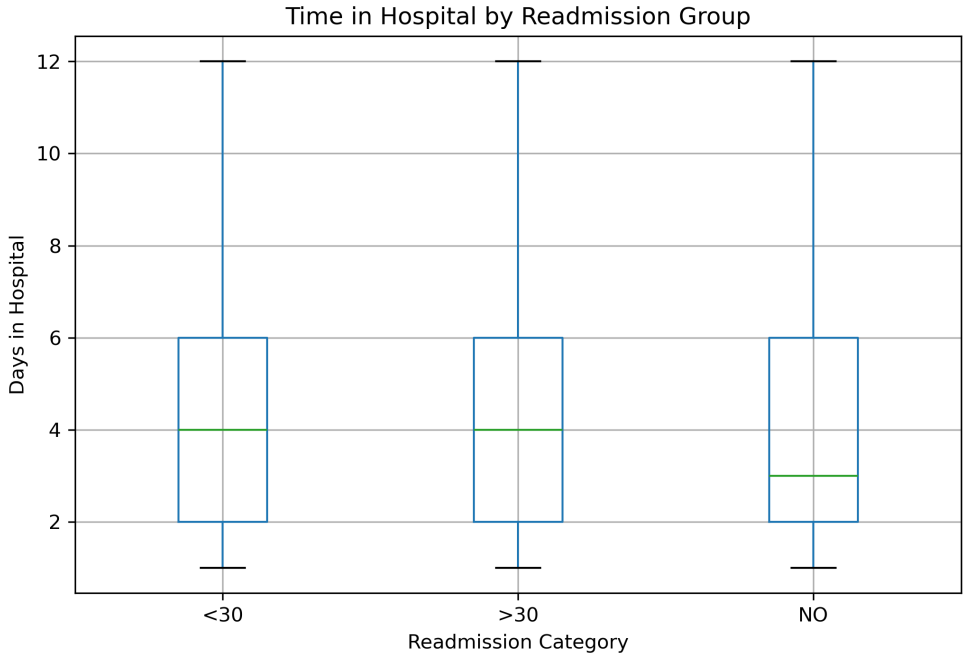
مصرف قبلی خدمات بستری روشن‌ترین تفکیک توصیفی را نشان می‌دهد. میانگین بستری‌های قبلی در مراجعه‌های دارای بستری مجدد زودهنگام ۱/۲۲ بود، در مقایسه با ۰/۸۴ در مراجعه‌های دارای بستری مجدد دیرهنگام و ۰/۳۸ در مراجعه‌های بدون بستری مجدد.



شکل ۵: بستری‌های قبلی بر حسب پیامد بستری مجدد. مراجعه‌های دارای بستری مجدد زودهنگام به سمت مصرف قبلی بیشتر خدمات بستری جابه‌جا شده‌اند.

طول مدت اقامت تفکیک‌کنندگیِ کمتری دارد. میانگین اقامت ۴/۷۷ روز برای بستری مجدد زودهنگام، ۴/۵۰ روز برای بستری مجدد دیرهنگام

و ۴/۲۵ روز برای بدون بستری مجدد بود.



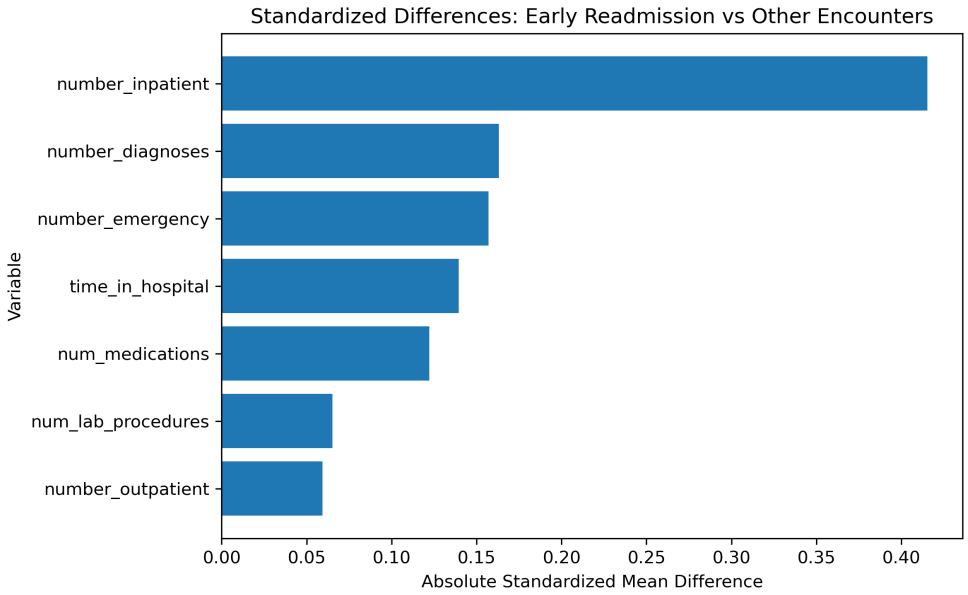
شکل ٦: مدت اقامت در بیمارستان بر حسب پیامد بستری مجدد. با وجود تفاوت اندک میانگین‌ها، توزیع‌ها هم‌پوشانی زیادی دارند.

۴.۵ تفاوت‌های استانداردشده

مقدار مطلق SMD برای `number_inpatient` برابر ۰/۴۱۵ بود که به‌مراتب بزرگ‌تر از سایر متغیرهای عددی است:

جدول ۷: مقادیر مطلق تفاوت میانگین استانداردشده میان بستری مجدد زودهنگام و سایر مراجعه‌ها.

متغیر	SMD مطلق
`number_inpatient`	۰/٤١٥
`number_diagnoses`	۰/۱۶۳
`number_emergency`	۰/۱۵۷
`time_in_hospital`	۰/۱۴۰
`num_medications`	۰/۱۲۲
`num_lab_procedures`	۰/۰۶۵
`number_outpatient`	۰/۰۵۹

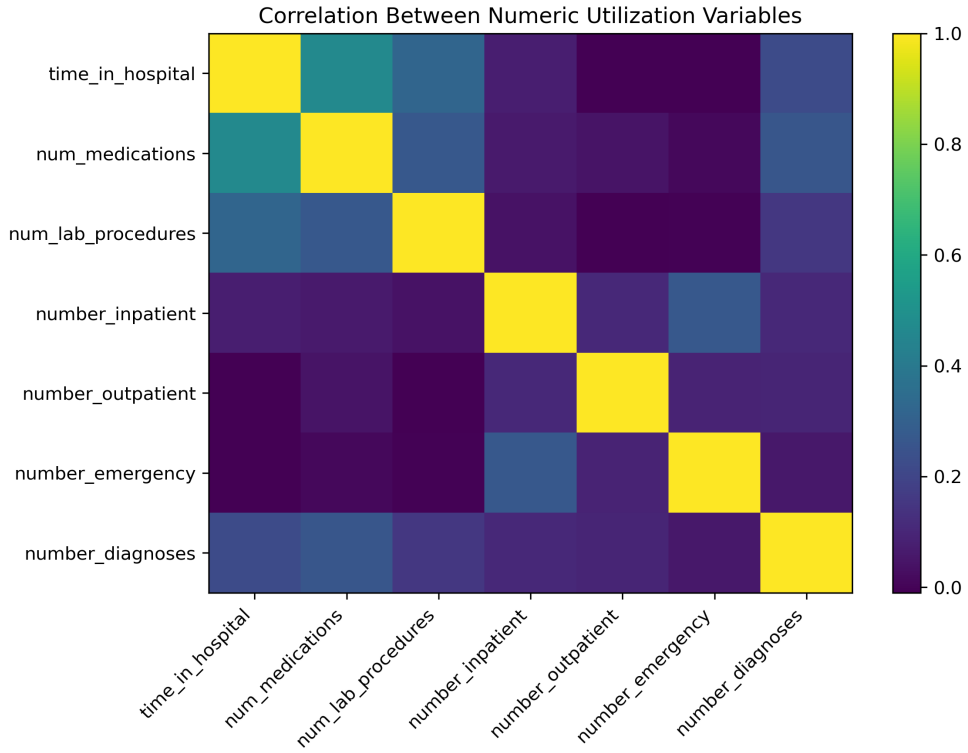


شکل ۷: مقادیر مطلق تفاوت‌های میانگین استانداردشده. مصرف قبلی خدمات بستری قوی‌ترین جداکننده‌ی عددی است.

مقدار ۰/۴۱۵ یک تفاوت استانداردشده‌ی کوچک تا متوسط است. مهم این است که این به معنای ناهم‌پوشانی توزیع‌ها نیست. توزیع تصویری در شکل ۵ هم‌پوشانی قابل‌توجه را تأیید می‌کند.

۴.۶ ساختار همبستگی

متغیرهای عددیِ مصرف خدمات همبستگی‌های دوبه‌دوی ضعیف تا متوسط دارند. بزرگ‌ترین همبستگی پیرسون ۰/۴۷ میان `time_in_hospital` و `num_medications` است؛ همبستگی میان `time_in_hospital` و `num_lab_procedures` برابر ۰/۳۲ و میان بستری‌های قبلی و مراجعه‌های اورژانس قبلی ۰/۲۷ است.



شکل ۸: ماتریس همبستگی پیرسون میان متغیرهای عددی مصرف خدمات. هیچ جفتی همبستگی خطی قوی نشان نمی‌دهد.

چون چند متغیر شمارشی با صفرهای فراوان و توزیع چوله‌اند، همبستگی پیرسون باید ابزار غربالگری توصیفی تلقی شود، نه توصیفی کامل از وابستگی.

۴.۷ ارتباط‌های طبقه‌ای

بزرگ‌ترین مقدار V کرامر برای مقصد ترخیص مشاهده شد:

$$V_{\text{discharge}} = 0.125.$$

مقادیر دیگر بسیار کوچک‌تر بودند.

جدول ۸: ضریب V کرامر برای متغیرهای طبقه‌ای منتخب و بستری مجدد زودهنگام.

متغیر	V کرامر
discharge_disposition	۰/۱۲۵
insulin	۰/۰۴۳
age	۰/۰۳۴
diabetesMed	۰/۰۲۷
admission_source	۰/۰۲۳
change	۰/۰۱۹
A1Cresult	۰/۰۱۹
admission_type	۰/۰۱۶
race	۰/۰۱۶
max_glu_serum	۰/۰۱۲
gender	۰/۰۰۳

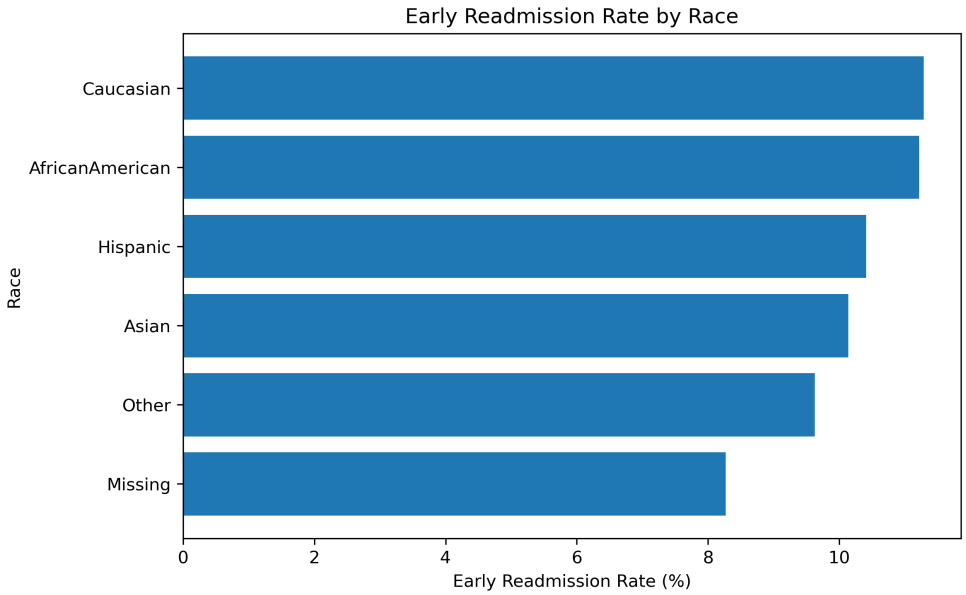
ارتباط مقصد ترخیص برای پیش‌بینی آگاهی‌بخش است اما از نظر بالینی تفسیرش دشوار است، زیرا مقصد بالینی را با دسته‌های اداری درآمیخته است. نباید آن را شاهدی بر این دانست که یک مقصد ترخیصِ مشخص موجب بستری مجدد می‌شود.

۴.۸ نژاد و جنسیت

نرخ‌های خام بستری مجدد زودهنگام برای بزرگ‌ترین گروه‌های نژادی مشابه بود.

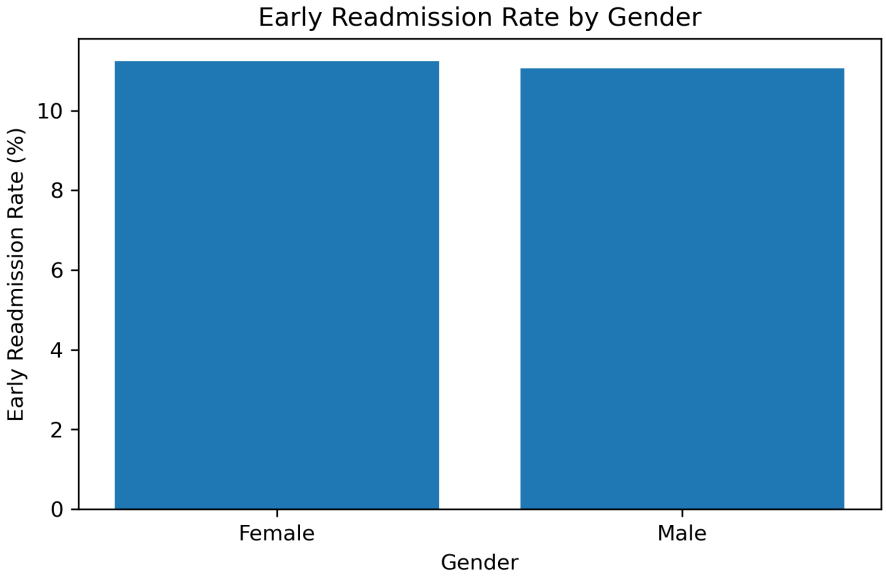
جدول ۹: نرخ بستری مجدد زودهنگام بر حسب نژاد.

نژاد	مراجعه‌ها	نرخ بستری مجدد زودهنگام
قفقازی (Caucasian)	۷۶٬۰۹۹	۱۱/۲۹٪
آفریقایی‌آمریکایی (African American)	۱۹٬۲۱۰	۱۱/۲۲٪
اسپانیایی‌تبار (Hispanic)	۲٬۰۳۷	۱۰/۴۱٪
آسیایی (Asian)	۶۴۱	۱۰/۱۴٪
سایر (Other)	۱٬۵۰۶	۹/۶۳٪
گمشده (Missing)	۲٬۲۷۳	۸/۲۷٪



شکل ۹: نرخ‌های خام بستری مجدد زودهنگام بر حسب نژاد. گروه‌های کوچک‌تر عدم قطعیتِ نمونه‌برداریِ وسیع‌تری دارند که در نمودار توصیفی نشان داده نشده است.

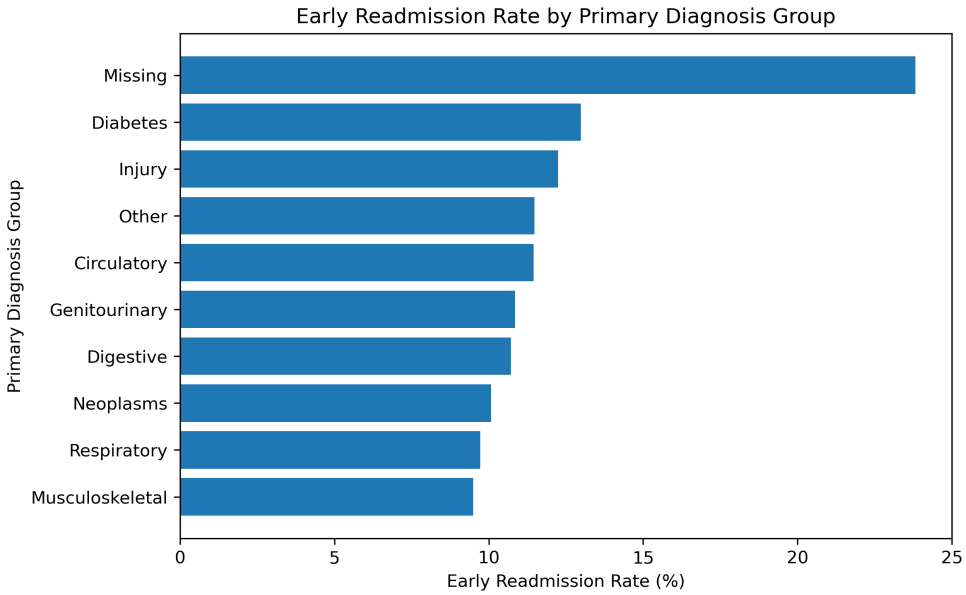
نرخ بستری مجدد زودهنگام در مراجعه‌های زنان ٪۱۱/۲۵ و در مراجعه‌های مردان ٪۱۱/۰۶ بود.



شکل ۱۰: نرخ بستری مجدد زودهنگام بر حسب جنسیت. نرخ‌های خام بسیار شبیه هم‌اند.

۴.۹ گروه تشخیص اصلی

در میان گروه‌های تشخیصیِ پرشمار، «دیابت» با ٪۱۲/۹۸ (۸,۷۵۷ مراجعه) بالاترین نرخ بستری مجدد زودهنگام را داشت و پس از آن «آسیب» با ٪۱۲/۲۵ قرار گرفت. گروه‌های تنفسی و اسکلتی‌عضلانی به‌ترتیب نرخ‌های ٪۹/۷۳ و ٪۹/۵۰ داشتند.



شکل ۱۱: نرخ بستری مجدد زودهنگام بر حسب گروه تشخیص اصلی. گروه بسیار کوچکِ «گمشده» نباید تفسیر شود.

این نرخ‌های گروهی توصیفی‌اند. دسته‌ی تشخیص خلاصه‌ای از اطلاعات کدگذاری‌شده است و ممکن است شدت بالینی، مرحله‌ی بیماری، وضعیت آزمایشگاهی یا عوامل اجتماعی تعیین‌کننده‌ی سلامت را منعکس نکند.

۵ نتایج مدل‌سازی پیش‌بینی

۵.۱ مقایسه‌ی مدل‌های مرحله‌ی الف

در آستانه‌ی پیش‌فرض ۰/۵۰، چهار مدل مقادیر ROC-AUC نسبتاً نزدیکی از ۰/۶۵۹ تا ۰/۶۸۳ نشان دادند.

جدول ۱۰: عملکرد مدل‌های مرحله‌ی الف در آستانه‌ی احتمال پیش‌فرض ۰/۵۰.

مدل	Accuracy	Bal. Acc.	Recall	Precision	F1	ROC-AUC	PR-AUC
رگرسیون لجستیک	۰/۶۵۵	۰/۶۱۷	۰/۵۶۸	۰/۱۷۸	۰/۲۷۲	۰/۶۶۴	۰/۲۲۱
درخت تصمیم	۰/۵۹۰	۰/۶۲۰	۰/۶۵۹	۰/۱۶۷	۰/۲۶۷	۰/۶۵۹	۰/۲۱۲
جنگل تصادفی	۰/۶۴۳	۰/۶۲۶	۰/۶۰۳	۰/۱۸۰	۰/۲۷۷	۰/۶۷۴	۰/۲۰۷
XGBoost	۰/۶۶۳	۰/۶۳۴	۰/۵۹۸	۰/۱۸۸	۰/۲۸۷	**۰/۶۸۳**	**۰/۲۳۸**

XGBoost در آستانه‌ی پیش‌فرض بهترین ROC-AUC، PR-AUC، صحت متوازن و F1 را دارد. با این حال تفاوت‌ها اندک‌اند و نتایج را نباید شاهدی بر برتری بزرگ یک الگوریتم نسبت به دیگری دانست.

۵.۲ نقاط کاری بازیابی‌محور

تنظیم آستانه یک نقطه‌ی کاری بالینیِ متفاوت پدید می‌آورد.

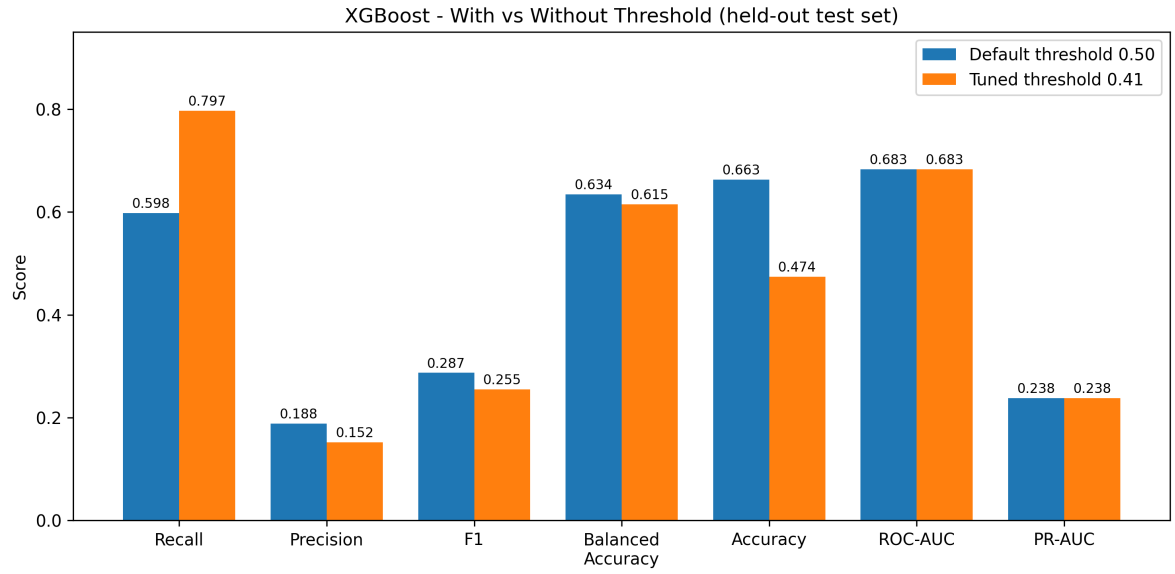
جدول ۱۱: عملکرد مرحله‌ی الف در آستانه‌های انتخاب‌شده با F_2 روی مجموعه‌ی اعتبارسنجی.

مدل	Thr.	Acc.	Bal. Acc.	Recall	Precision	F1	ROC-AUC	PR-AUC
رگرسیون لجستیک	۰/۳۹	۰/۴۴۸	۰/۵۹۷	۰/۷۹۱	۰/۱۴۵	۰/۲۴۵	۰/۶۶۴	۰/۲۲۱
درخت تصمیم	۰/۳۸	۰/۴۴۴	۰/۵۹۳	۰/۷۸۶	۰/۱۴۳	۰/۲۴۳	۰/۶۵۹	۰/۲۱۲
جنگل تصادفی	۰/۴۵	۰/۴۲۶	۰/۶۰۲	**۰/۸۳۰**	۰/۱۴۵	۰/۲۴۷	۰/۶۷۴	۰/۲۰۷
XGBoost	۰/۴۱	۰/۴۷۴	**۰/۶۱۵**	۰/۷۹۷	**۰/۱۵۲**	**۰/۲۵۵**	**۰/۶۸۳**	**۰/۲۳۸**

این نتیجه یک مصالحه‌ی عملیاتی محوری را نشان می‌دهد. برای XGBoost، حرکت از آستانه‌ی پیش‌فرض به ۰/۴۱ بازیابی را از ۰/۵۹۸ به ۰/۷۹۷ می‌رساند، اما دقت تنها ۰/۱۵۲ می‌ماند و صحت به ۰/۴۷۴ می‌افتد. بدین‌ترتیب در این نقطه‌ی کاری تقریباً شش مراجعه از هر ده مراجعه‌ی آزمون علامت‌گذاری می‌شود.

۵.۳ آستانه‌ی تصمیم: اثر آن بر XGBoost

یک طبقه‌بند احتمالاتی امتیاز ریسک تولید می‌کند؛ آستانه‌ی تصمیم تعیین می‌کند که از چه امتیازی به بالا، مراجعه به‌عنوان بستری مجدد زودهنگام محتمل علامت‌گذاری شود. با شیوع پیامد در حدود ۱۱٪، حد جداکننده‌ی پیش‌فرض ۰/۵۰ نقطه‌ی کاری نامناسبی است، وقتی از دست دادن یک بستری مجدد زودهنگام واقعی گران‌تر از یک هشدار کاذب باشد. بنابراین آستانه به‌صراحت انتخاب شد: برای هر مدل، مقداری در بازه‌ی $[0.05,\ 0.50]$ (با گام ۰/۰۱) که F_2 را روی یک مجموعه‌ی اعتبارسنجیِ جداشده بر اساس بیمار بیشینه می‌کرد برگزیده شد، مدل روی کل مجموعه‌ی آموزش دوباره برازش شد، و مجموعه‌ی آزمون هرگز برای انتخاب آستانه به کار نرفت (بدون نشت). برای XGBoost آستانه‌ی انتخاب‌شده ۰/۴۱ بود. شکل ۱۲ و جدول ۱۲ مدل XGBoost مرحله‌ی الف را روی مجموعه‌ی آزمون نگه‌داشته‌شده، با و بدون این آستانه مقایسه می‌کنند.



شکل ۱۲: XGBoost مرحله‌ی الف روی مجموعه‌ی آزمون نگه‌داشته‌شده: آستانه‌ی ۰/۴۱ تنظیم‌شده روی اعتبارسنجی در برابر آستانه‌ی پیش‌فرض ۰/۵۰. ROC-AUC و PR-AUC به آستانه وابسته نیستند؛ آستانه بازیابی را از ۰/۵۹۸ به ۰/۷۹۷ می‌رساند، به بهای کاهش دقت و صحت.

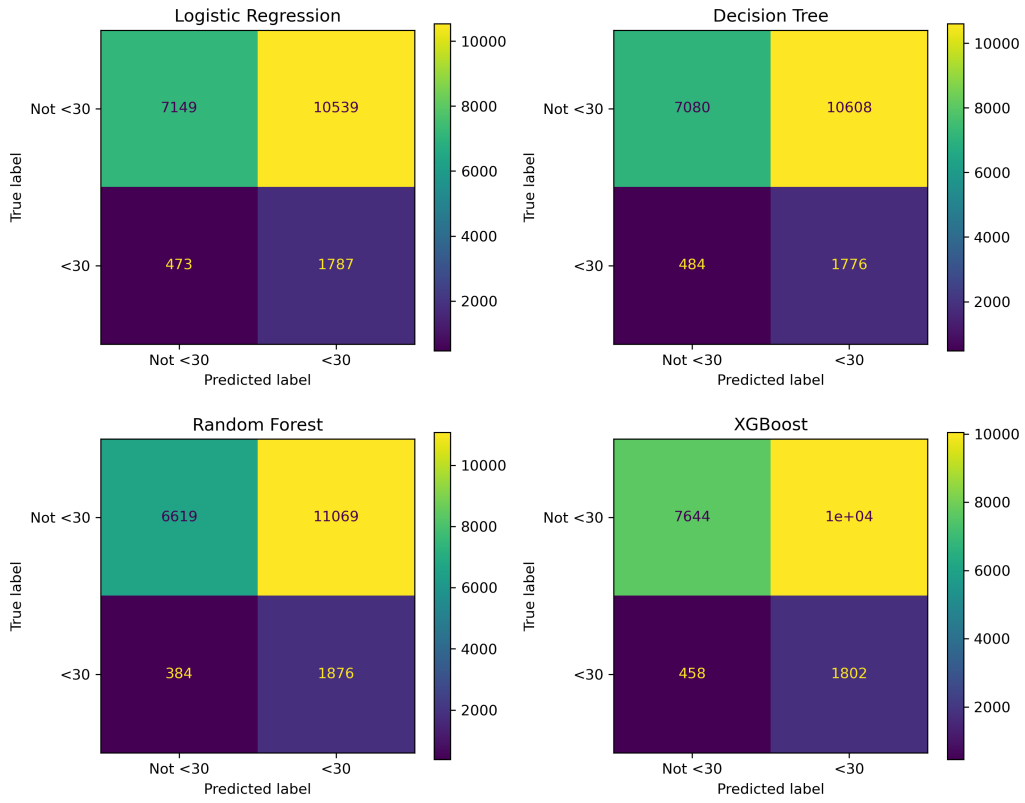
جدول ۱۲: اثر آستانه‌ی تصمیم بر XGBoost مرحله‌ی الف (مجموعه‌ی آزمون نگه‌داشته‌شده). مقادیر علامت‌دار با † از بازیابی، دقت و اندازه‌ی مجموعه‌ی آزمونِ گزارش‌شده استخراج شده‌اند.

معیار	آستانه‌ی ۰/۴۱	پیش‌فرض ۰/۵۰	تغییر
Recall (< 30)	**۰/۷۹۷**	۰/۵۹۸	+۰/۱۹۹ (+۳۳٪ نسبی)
Precision (< 30)	۰/۱۵۲	۰/۱۸۸	−۰/۰۳۶
F1 (< 30)	۰/۲۵۵	۰/۲۸۷	−۰/۰۳۲
صحت متوازن	۰/۶۱۵	۰/۶۳۴	−۰/۰۱۹
صحت (Accuracy)	۰/۴۷۴	۰/۶۶۳	−۰/۱۸۹
ROC-AUC	۰/۶۸۳	۰/۶۸۳	۰ (مستقل از آستانه)
PR-AUC	۰/۲۳۸	۰/۲۳۸	۰ (مستقل از آستانه)
F_2 (استخراج‌شده)†	۰/۴۳۱	۰/۴۱۶	+۰/۰۱۵
بستری‌های مجدد زودهنگام واقعیِ شناسایی‌شده (از ۲٬۲۶۰)	۱٬۸۰۲	†۱٬۳۵۱≈	+۴۵۱≈
مراجعه‌های علامت‌گذاری‌شده (از ۱۹٬۹۴۸)	۱۱٬۸۴۶ (۵۹/۴٪)	۷٬۲۰۰≈ (۳۶٪≈)†	+۴٬۶۵۰≈

مقادیر استخراج‌شده خطای گردکردنی در حدود $\pm 0.5\%$ پایه دارند. حرکت از ۰/۵۰ به ۰/۴۱ نحوه‌ی **رتبه‌بندی** بیماران توسط مدل را تغییر نمی‌دهد (ROC-AUC و PR-AUC یکسان‌اند)؛ جایی را که هشدار در آن فعال می‌شود تغییر می‌دهد. این آستانه حدود ۴۵۰ بستری مجدد زودهنگام واقعیِ بیشتر را بازیابی می‌کند (بازیابی از ۰/۵۹۸ به ۰/۷۹۷) و بهایش حدود ده هشدار اضافه به ازای هر مورد اضافیِ شناسایی‌شده است (استخراج‌شده). این تنها انتخاب طراحی‌ای است که بیش از همه توان مدل را در شناسایی موارد مهم بهبود می‌دهد، و همان است که صحت را پایین می‌آورد؛ به همین دلیل از صحت برای قضاوت درباره‌ی مدل استفاده نمی‌شود. آستانه‌ی مناسب به ظرفیت بازبینی بستگی دارد: بیمارستانی که می‌تواند هشدارهای کمتری را بازبینی کند باید آستانه‌ی بالاتری برگزیند.

۵.۴ ماتریس‌های درهم‌ریختگی

ماتریس‌های درهم‌ریختگی مصالحه را ملموس می‌کنند.



شکل ۱۳: ماتریس‌های درهم‌ریختگی در آستانه‌های بازیابی‌محور. بازیابی بالا به بهای شمار زیادی هشدار مثبت کاذب به دست می‌آید.

برای XGBoost تنظیم‌شده، مجموعه‌ی آزمون ۱٫۸۰۲ مثبت درست، ۴۵۸ منفی کاذب، ۱۰٫۰۴۴ مثبت کاذب و ۷٫۶۴۴ منفی درست دارد. FNR حاصل برابر است با:

$$\mathrm{FNR} = \frac{458}{458 + 1802} = 0.203.$$

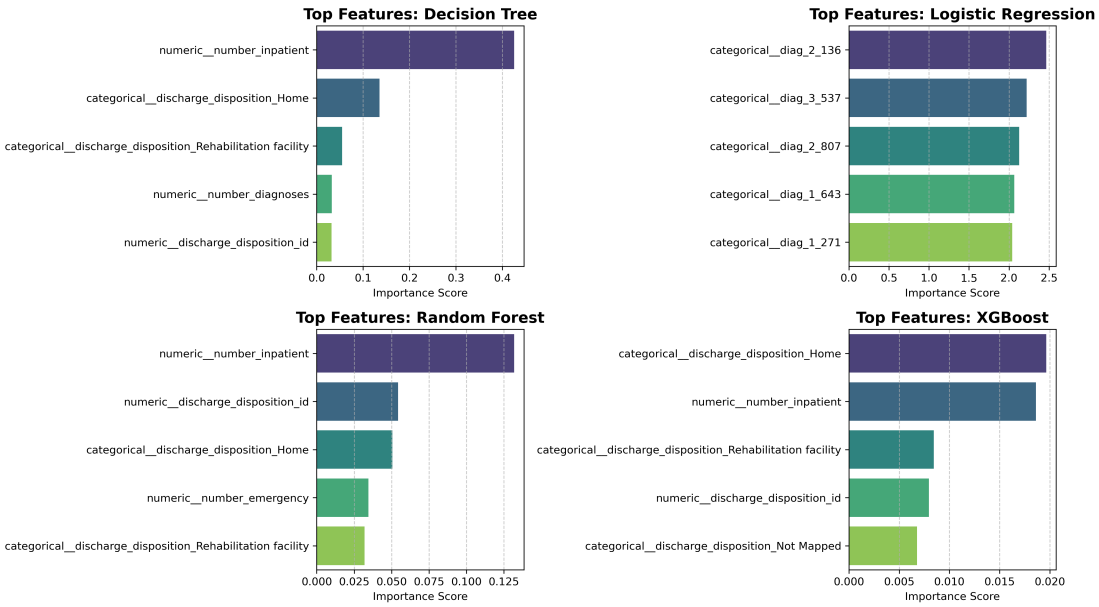
شمار زیاد مثبت‌های کاذب به این معناست که پیاده‌سازی بالینی ظرفیت بازبینی قابل‌توجهی می‌طلبد.

۵.۵ اهمیت ویژگی‌ها

در مدل‌های مبتنی بر درخت، سابقه‌ی بستری قبلی و مقصد ترخیص به‌طور مداوم در میان قوی‌ترین پیش‌بینی‌کننده‌ها دیده می‌شوند.

جدول ۱۳: پیش‌بینی‌کننده‌های پیشرو بر حسب مدل.

مدل	قوی‌ترین ویژگی‌های گزارش‌شده
درخت تصمیم	`number_inpatient` (۰/۴۲۵)؛ مقصد ترخیص «خانه» (۰/۱۳۵)؛ «توان‌بخشی» (۰/۰۵۵)
جنگل تصادفی	`number_inpatient` (۰/۱۳۲)؛ `discharge_disposition_id` (۰/۰۵۴)؛ «خانه» (۰/۰۵۱)
XGBoost	«خانه» (۰/۰۲۰)؛ `number_inpatient` (۰/۰۱۹)؛ «توان‌بخشی» (۰/۰۰۹)
رگرسیون لجستیک	ضرایب کدهای تشخیصیِ نادر، از جمله `diag_2_136` و `diag_3_537`



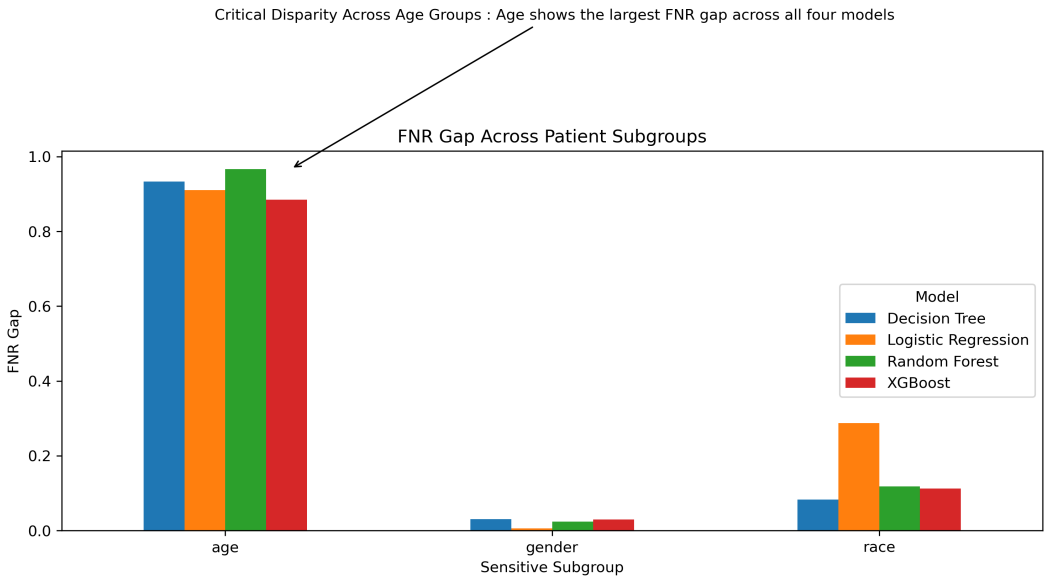
شکل ۱۴: برترین ویژگی‌ها و ضرایب در چهار مدل مرحله‌ی الف. اهمیت نشان‌دهنده‌ی سهم در مدل است، نه اثر علّی.

نتیجه‌ی رگرسیون لجستیک نیازمند احتیاط است، زیرا ماتریس یک‌داغِ بسیار پهن شامل سطوح تشخیصیِ نادر است. ضرایب بزرگ برای دسته‌های نادر می‌توانند ناپایدار باشند و بدون تکرارپذیری نباید به‌عنوان عوامل خطر بالینیِ استوار تفسیر شوند.

۵.۶ تحلیل خطای زیرگروه‌ها

جدول ۱۴: شکاف FNR زیرگروه‌ها در مرحله‌ی الف در آستانه‌های بازیابی‌محور.

مدل	شکاف FNR نژاد	شکاف FNR سن	شکاف FNR جنسیت
رگرسیون لجستیک	۰/۲۸۸	۰/۹۱۰	۰/۰۰۶
درخت تصمیم	۰/۰۸۳	۰/۹۳۳	۰/۰۳۱
جنگل تصادفی	۰/۱۱۸	۰/۹۶۷	۰/۰۲۴
XGBoost	۰/۱۱۲	۰/۸۸۵	۰/۰۲۹



شکل ۱۵: تفاوت بیشینه و کمینه‌ی FNR درون زیرگروه‌های نژاد، جنسیت و سن.

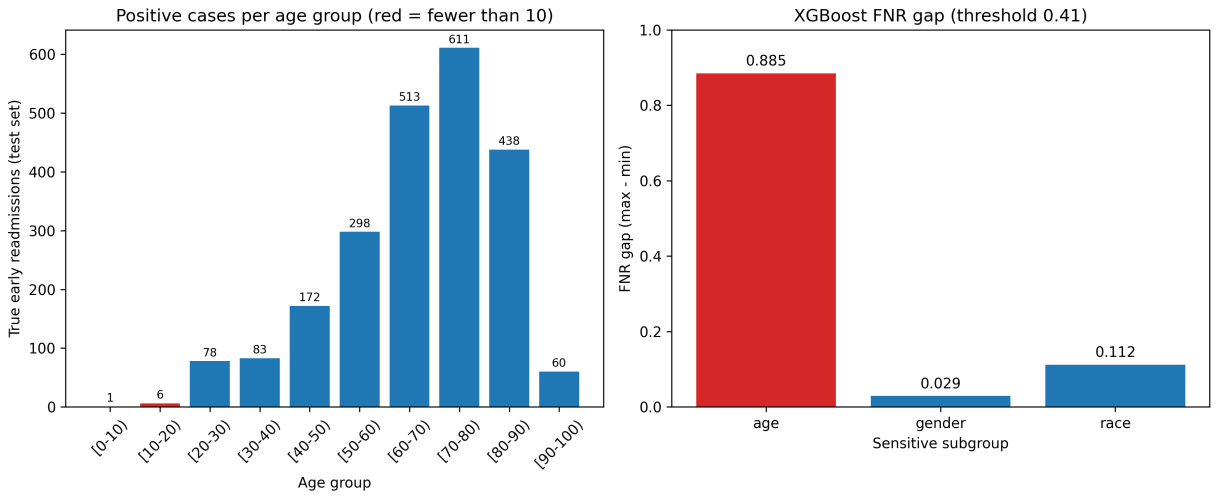
شکاف‌های گروه‌های سنی از نظر عددی بزرگ‌اند، اما شمار موارد مثبت زیربنایی اندک است. برای مثال، مجموعه‌ی آزمونِ بازتولیدشده در گروه [0–10) فقط ۲۷ مراجعه و یک مورد بستری مجدد زودهنگام، و در گروه [10–20) ۱۱۹ مراجعه با شش مورد مثبت دارد. بنابراین FNR برابر ۱/۰ می‌تواند از دست رفتن تنها یک رویداد ناشی شود. به همین ترتیب، دسته‌ی «گمشده» در جنسیت فقط یک مراجعه و هیچ مورد مثبت ندارد و FNR آن از نظر بالینیِ معنادار تعریف‌نشده است. این یافته‌ها اهمیت گزارش اندازه‌ی نمونه‌ی زیرگروه‌ها در کنار معیارهای نابرابری را نشان می‌دهند.

۵.۶.۱ نابرابری گروه‌های سنی و پشتوانه‌ی آماری آن

نتایج گروه‌های سنی جدی‌ترین یافته‌ی انصاف در این پروژه است. هر چهار مدل دست‌کم در یک گروه سنی همه‌ی بستری‌های مجدد زودهنگام را از دست می‌دهند (FNR = 1.00) و شکاف FNR میان گروه‌های سنی ۰/۸۸۵ تا ۰/۹۶۷ است. جدول ۱۵ شمار مراجعه‌های آزمون و بستری‌های مجدد زودهنگام واقعی را در هر گروه نشان می‌دهد.

جدول ۱۵: مجموعه‌ی آزمون نگه‌داشته‌شده: مراجعه‌ها و بستری‌های مجدد زودهنگام واقعی (موارد مثبت) در هر گروه سنی. با اجرای دوباره‌ی تقسیم گروهی با `random_state=123` استخراج شده است؛ مجموع‌ها با دفترچه‌ی تحلیل مطابقت دارند.

گروه سنی	مراجعه‌های آزمون	بستری‌های مجدد زودهنگام واقعی
[0–10)	۲۷	۱
[10–20)	۱۱۹	٦
[20–30)	۳۹۶	۷۸
[30–40)	۷۴۳	۸۳
[40–50)	۱,۸۳۷	۱۷۲
[50–60)	۳,۳۸۷	۲۹۸
[60–70)	۴,۵۰۴	۵۱۳
[70–80)	۵,۱۲۷	۶۱۱
[80–90)	۳,۲۸۱	۴۳۸
[90–100)	۵۲۷	۶۰
مجموع	۱۹,۹۴۸	۲,۲۶۰



شکل ۱۶: نابرابری زیرگروه‌های سنی و پشتوانه‌ی آماری آن. چپ: شمار بستری‌های مجدد زودهنگام واقعی در هر گروه سنی در مجموعه‌ی آزمون (قرمز = کمتر از ۱۰). راست: شکاف FNR (بیشینه منهای کمینه) برای نژاد، جنسیت و سن در XGBoost مرحله‌ی الف با آستانه‌ی ۰/۴۱.

با تنها ۱ و ۶ مورد مثبت در دو گروه سنیِ جوان‌تر، FNR برابر ۱/۰۰ می‌تواند از یک مورد از دست رفته ناشی شود؛ پس **بزرگی دقیق** شکاف نامطمئن است و بازه‌های اطمینان در سطح زیرگروه محاسبه نشده‌اند. این عدم قطعیت اندازه‌ی برآورد را مشروط می‌کند، اما یافته را از بین نمی‌برد. مدل هیچ شاهدی بر توانایی شناسایی بستری‌های مجدد زودهنگام در بیماران زیر ۲۰ سال نشان نمی‌دهد، و شکل خودِ دفترچه‌ی تحلیل (شکل ۱۵) نیز آن را نابرابری بحرانی برچسب می‌زند. پیامدهای عملی عبارت‌اند از:

۱. مدل نباید بدون اعتبارسنجی جداگانه برای بیماران زیر ۲۰ سال به کار رود؛
۲. بازیابی در گروه‌های سنی باید با بازه‌های اطمینان گزارش شود؛
۳. کالیبراسیون آگاه از سن یا آستانه‌های ویژه‌ی هر گروه سنی باید در نظر گرفته شود؛
۴. باید موارد بیشتری در این گروه‌ها گردآوری یا ادغام شود.

شکاف‌های نژاد متوسط‌اند (بزرگ‌ترین آن‌ها برای رگرسیون لجستیک، ۰/۲۸۸) و شکاف‌های جنسیت کوچک‌اند (۰/۰۰۶ تا ۰/۰۳۱). مقدار $\min_\text{Recall} = 0.000$ گزارش‌شده برای جنسیت از گروه «گمشده»ی جنسیت با یک مراجعه و بدون مورد مثبت ناشی می‌شود (که با `zero_division=0` امتیاز صفر گرفته است) و شکست مدل نیست.

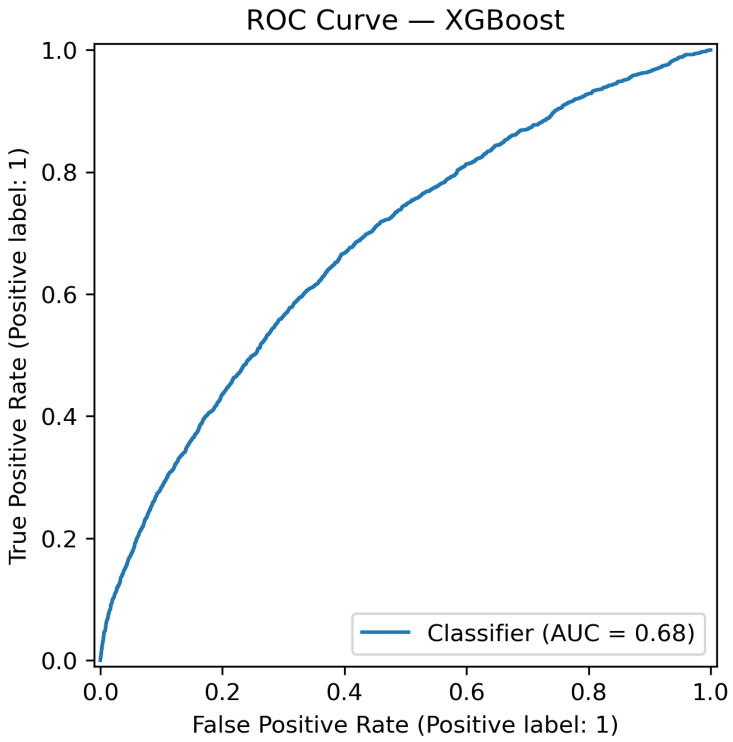
۵.۷ مدل نهایی XGBoost در مرحله‌ی ب

مدل XGBoost مرحله‌ی دوم با اعتبارسنجی متقاطع تصادفیِ گروهی بهینه شد. بهترین ترکیب پارامترهای آن F_2 اعتبارسنجی‌متقاطع برابر ۰/۴۰۶ داد. هنگامی که در آستانه‌ی ثابت ۰/۵۰ روی مجموعه‌ی آزمون نگه‌داشته‌شده ارزیابی شد، نتایج زیر به دست آمد:

جدول ۱۶: مدل نهایی XGBoost با ابرپارامترهای جست‌وجوشده روی مجموعه‌ی آزمون نگه‌داشته‌شده.

معیار	مقدار
صحت (Accuracy)	۰/۶۴۰
Recall	۰/۶۱۹
Precision	۰/۱۸۱
F1	۰/۲۸۰
ROC-AUC	≈ 0.68
میانگین کلان دقت	۰/۵۵۵
میانگین کلان بازیابی	۰/۶۳۱
میانگین کلان F1	۰/۵۲۰

نتیجه‌ی مرحله‌ی ب را نباید با XGBoost مرحله‌ی الف در آستانه‌ی ۰/۴۱ اشتباه گرفت. این‌ها پیکربندی‌ها و نقاط کاریِ متفاوتی هستند. مرحله‌ی الف برای نشان دادن مصالحه‌ی بازیابی–دقت مفید است؛ مرحله‌ی ب پیکربندی نهاییِ جست‌وجوشده‌ای است که پروژه گزارش کرده است.



شکل ۱۷: منحنی ROC برای مدل نهایی XGBoost. توان تفکیک گزارش‌شده متوسط است و ROC-AUC حدود ۰/۶۸ است.

۶ یافته‌های کلیدی

۱. **مسئله دودویی و نامتوازن است:** ٪۱۱/۱۶ از ۱۰۱,۷۶۶ مراجعه ظرف ۳۰ روز با بستری مجدد دنبال شدند (٪۱۱/۳۹ در هم‌گروه مدل‌سازی با ۹۹,۳۴۳ مراجعه؛ ٪۱۱/۳۳ در مجموعه‌ی آزمون).

۲. **آستانه‌ی تصمیم، نقطه‌ی قوت کلیدی مدل است:** XGBoost در آستانه‌ی ۰/۴۱ تنظیم‌شده روی اعتبارسنجی به بازیابی ۰/۷۹۷ در برابر ۰/۵۹۸ در آستانه‌ی پیش‌فرض ۰/۵۰ می‌رسد، با ROC-AUC (۰/۶۸۳) و PR-AUC (۰/۲۳۸) یکسان. بهای آن دقت ۰/۱۵۲

(در برابر ۰/۱۸۸) و صحت ۰/۴۷۴ (در برابر ۰/۶۶۳) است.

۳. **نابرابری شدید در گروه‌های سنی:** شکاف FNR میان گروه‌های سنی در هر چهار مدل ۰/۸۸۵ تا ۰/۹۶۷ است و دست‌کم یک گروه $\text{FNR} = 1.00$ دارد. این بزرگ‌ترین مسئله‌ی انصاف در پروژه است؛ گروه‌های درگیر فقط ۱ و ۶ مورد مثبت دارند، بنابراین اندازه‌ی دقیق آن نامطمئن است.

۴. **سابقه‌ی بستری قبلی روشن‌ترین سیگنال است:** `number_inpatient` بزرگ‌ترین SMD (۰/۴۱۵) را دارد؛ میانگین بستری‌های قبلی ۱/۲۲ برای $30 <$ در برابر ۰/۳۸ برای NO است. همچنین در همه‌ی مدل‌های مبتنی بر درخت ویژگی اول یا دوم است.

۵. **بیشتر ارتباط‌های دیگر ضعیف‌اند:** همه‌ی مقادیر V کرامر ≤ 0.125 هستند؛ ارتباط‌های گروه‌های تشخیص حدود ۰/۰۲ تا ۰/۰۳ است.

۶. **مقصد ترخیص آگاهی‌بخش اما دشوار تفسیر است** ($V = 0.125$)؛ در همه‌ی مدل‌های درختی برجسته است)، چون مقصد بالینی را با دسته‌های اداری درمی‌آمیزد.

۷. **صحت گمراه‌کننده است:** بالا بردن بازیابی تا حدود ۰/۸۰ صحت را به حدود ۰/۴۳ تا ۰/۴۷ می‌رساند و دقت را در حدود ۰/۱۴ تا ۰/۱۵ می‌گذارد.

۸. **مدل‌ها از نظر توان تفکیک به هم نزدیک‌اند:** ROC-AUC از ۰/۶۵۹ تا ۰/۶۸۳؛ XGBoost در ROC-AUC (۰/۶۸۳) و PR-AUC (۰/۲۳۸) بهترین است.

۹. **یک XGBoost با ابرپارامترهای جست‌وجوشده** (تکمیلی، آستانه‌ی ۰/۵۰) به بازیابی ۰/۶۱۹، دقت ۰/۱۸۱، F1 برابر ۰/۲۸۰ و ROC-AUC حدود ۰/۶۸ می‌رسد.

۱۰. **شکاف‌های نژاد و جنسیت به‌ترتیب متوسط و کوچک‌اند** (شکاف FNR: ۰/۰۸۳ تا ۰/۲۸۸ و ۰/۰۰۶ تا ۰/۰۳۱).

۱۱. **نشت در سطح بیمار کنترل شد:** هیچ بیماری هم در آموزش و هم در آزمون حضور ندارد، اعتبارسنجی متقاطع گروهی بر اساس بیمار بود و آستانه بدون استفاده از مجموعه‌ی آزمون انتخاب شد.

۷ تفسیر بالینی

۷.۱ مصرف قبلی خدمات بستری

پایدارترین سیگنال، مصرف قبلی خدمات بستری است. تحلیل اندازه‌ی اثر، میانگین‌های گروهی و اهمیت ویژگی در مدل‌های درختی همگی در یک جهت‌اند. این از نظر بالینی به‌عنوان نشانگر نیازهای درمانیِ پیچیده یا ناپایدار موجه است، اما داده‌های مشاهده‌ای نمی‌توانند ثابت کنند که خودِ بستری قبلی موجب بستری مجدد آینده می‌شود.

برای کاربرد عملیاتی، مصرف قبلی خدمات بستری را می‌توان نشانگر طبقه‌بندی ریسک در نظر گرفت. تیم مدیریت مراقبت می‌تواند آن را یکی از اجزای یک فرایند بازبینیِ گسترده‌تر به کار گیرد، به‌ویژه همراه با برنامه‌ریزی ترخیص و سایر اطلاعات بالینی که در این مجموعه‌داده به‌طور کامل نمایندگی نشده‌اند.

۷.۲ مقصد ترخیص

مقصد ترخیص بزرگ‌ترین ارتباط طبقه‌ای را دارد و در همه‌ی مدل‌های درختی برجسته است. با این حال باید محتاطانه تفسیر شود. دسته‌های مقصد می‌توانند نقطه‌ی پایانی اداریِ یک بستری را کدگذاری کنند و ممکن است اطلاعاتی را بازتاب دهند که بسیار دیر در مسیر مراقبت در دسترس می‌شود. همچنین می‌توانند مقصد بالینی را با ساختار کدگذاری درآمیزند. در نتیجه، اهمیت ویژگی به این معنا نیست که تغییر مقصد ترخیص لزوماً ریسک بستری مجدد را تغییر دهد.

۷.۳ معنای عملی دقت

دقت ۰/۱۵۲ در آستانه‌ی بازیابی‌محور XGBoost یعنی در مجموعه‌ی آزمون نگه‌داشته‌شده تنها حدود ۱۵ مورد از هر ۱۰۰ مراجعه‌ی علامت‌گذاری‌شده بستری مجدد زودهنگام‌اند. بقیه‌ی هشدارها مثبت کاذب‌اند. این در یک سامانه‌ی غربالگری لزوماً غیرقابل‌قبول نیست، اما حجم کار

لازم از پرستاران، هماهنگ‌کنندگان مراقبت یا پزشکان را تعیین می‌کند.

در آستانه‌ی ۰/۴۱ XGBoost مرحله‌ی الف، ۱۱٬۸۴۶ مراجعه از ۱۹٬۹۴۸ مراجعه‌ی آزمون علامت‌گذاری شد، یعنی ٪۵۹/۴ مجموعه‌ی آزمون. این نقطه‌ی کاری ٪۷۹/۷ از بستری‌های مجدد زودهنگام واقعی را می‌گیرد اما صف بازبینی بسیار بزرگی می‌سازد. بنابراین استقرار واقعی به یک قید صریح ظرفیت و ارزیابی آینده‌نگر ارزشِ هر هشدار نیاز دارد.

نسبت افزایش (lift) نسبت به نرخ پایه (استخراج‌شده). شیوع در مجموعه‌ی آزمون ٪۱۱/۳۳ است. دقت ۰/۱۵۲ XGBoost مرحله‌ی الف در آستانه‌ی ۰/۴۱ حدود ۱/۳ برابر نرخ پایه است، در حالی که ۰/۱۸۸ در آستانه‌ی پیش‌فرض ۰/۵۰ حدود ۱/۷ برابر و ۰/۱۸۱ مدل مرحله‌ی ب حدود ۱/۶ برابر است. بنابراین آستانه بازیابی می‌خرد، نه دقت: سیگنال آماری واقعی است اما از نظر عملیاتی پرهزینه است. در آستانه‌ی پیش‌فرض، مدل تقریباً ٪۳۶ مراجعه‌ها را علامت می‌زند (استخراج‌شده) و ٪۵۹/۸ بستری‌های مجدد زودهنگام را می‌گیرد، در مقابل ٪۵۹/۴ علامت‌گذاری‌شده و ٪۷۹/۷ گرفته‌شده در ۰/۴۱.

۷.۴ کاربرد مدل به‌عنوان پشتیبان تصمیم

مدل را باید ابزار رتبه‌بندی یا اولویت‌بندی دانست. بیماری را تشخیص نمی‌دهد، درمان تجویز نمی‌کند و ثابت نمی‌کند که مداخله‌ای از بستری مجدد جلوگیری خواهد کرد. بازبینی انسانی ضروری است، به‌ویژه چون مجموعه‌داده تاریخی، اداری و از نظر شدت بالینی و زمینه‌ی اجتماعی ناقص است.

۸ انصاف، قابلیت اتکا و عدم قطعیت

ارزیابی الگوریتمی در حوزه‌ی سلامت به چیزی فراتر از یک معیار کلی نیاز دارد. مدلی ممکن است توان تفکیک کلی قابل‌قبولی داشته باشد و در عین حال موارد را به‌طور نامتناسب در یک زیرگروه از دست بدهد. بنابراین پروژه‌ی حاضر شکاف‌های FNR را برای نژاد، جنسیت و سن گزارش می‌کند.

شکاف‌های نژاد در مدل‌های مرحله‌ی الف از ۰/۰۸۳ تا ۰/۲۸۸ و شکاف‌های جنسیت از ۰/۰۰۶ تا ۰/۰۳۱ بود. شکاف‌های سنی بسیار بزرگ‌تر بود، از ۰/۸۸۵ تا ۰/۹۶۷. اما نتایج سنی تحت تأثیر شمار اندک موارد مثبت‌اند. این تمایز مهم است: نابرابریِ مشاهده‌شده‌ی بزرگ معادل شواهد قوی از تبعیض نظام‌مند نیست. با این حال یافته نادیده گرفته نمی‌شود: چون هر مدل دست‌کم در یک گروه سنی همه‌ی بستری‌های مجدد زودهنگام را از دست می‌دهد، مدل‌ها نباید بدون اعتبارسنجی جداگانه برای بیماران درگیر استفاده شوند.

چند شکل از عدم قطعیت کمّی نشده باقی مانده است. پروژه از یک تقسیم گروهیِ آموزش/آزمون استفاده کرد، بنابراین بازه‌های اطمینان برای معیارهای عملکرد محاسبه نشد. تقسیم‌های گروهیِ مکرر یا بازه‌های اطمینان بوت‌استرپ توصیف بهتری از تغییرپذیری نمونه‌گیری می‌دهند. منحنی‌های کالیبراسیون و خطای کالیبراسیون مورد انتظار نیز مفیدند، زیرا ROC-AUC رتبه‌بندی را می‌سنجد، نه اینکه احتمال‌های پیش‌بینی‌شده با ریسک‌های مشاهده‌شده مطابقت دارند.

یک ارزیابی بالینیِ بالغ‌تر افزون بر این موارد را نیز بررسی می‌کرد:

۱. کالیبراسیون در کل و درون زیرگروه‌های مهم؛
۲. بازه‌های اطمینان برای بازیابی، دقت، ROC-AUC و PR-AUC؛
۳. تحلیل منحنی تصمیم یا سایر معیارهای سود خالص؛
۴. اعتبارسنجی زمانی روی مراجعه‌های جدیدتر؛
۵. اعتبارسنجی بیرونی در یک نظام سلامت جداگانه؛
۶. تعریف زیرگروه‌های بالینیِ معنادار با شمار کافی رویداد مثبت.

۹ محدودیت‌ها

۱. **نابرابری زیرگروه‌های سنی (بحرانی):** هر چهار مدل دست‌کم در یک گروه سنی همه‌ی بستری‌های مجدد زودهنگام را از دست می‌دهند (FNR = 1.00؛ شکاف ۰/۸۸۵ تا ۰/۹۶۷). گروه‌های درگیر جوان‌ترین گروه‌ها هستند و ۱ و ۶ مورد مثبت دارند، بنابراین بزرگی آن نامطمئن است، اما مدل نباید بدون اعتبارسنجی جداگانه برای این بیماران به کار رود.

۲. **داده‌های تاریخی:** داده‌های منبع در سال ۲۰۰۸ پایان می‌یابد. مسیرهای بالینی، کدگذاری، داروها و مصرف خدمات درمانی از آن زمان به‌طور چشمگیری تغییر کرده‌اند.

۳. **یک تقسیم نگه‌داشته‌شده:** نتایج اصلی آزمون از یک تقسیم گروهیِ بیمار–محور به دست آمده است. تقسیم مکرر و بازه‌های اطمینان انجام نشد.

۴. **زیرگروه‌های کوچک:** چند گروه سنی و نژادی رویدادهای مثبت اندکی دارند که قابلیت اتکای برآوردهای FNR زیرگروه‌ها را محدود می‌کند.

۵. **ثبت پیامد:** بستری‌های مجددی که خارج از نظام بیمارستانیِ منبع رخ داده‌اند ممکن است مشاهده نشده باشند.

۶. **زمینه‌ی بالینی گمشده:** عوامل اجتماعی تعیین‌کننده‌ی سلامت، روند تفصیلی آزمایشگاهی، شدت بیماری و ارزیابی پزشک به‌طور ناقص نمایندگی شده‌اند.

۷. **بازنمایی ویژگی‌ها:** شناسه‌های اداریِ اسمی تا حدی عددی در نظر گرفته شدند و کدهای تشخیصی خامِ پرکاردینالیتی یک‌داغ کدگذاری شدند. این انتخاب‌ها ممکن است نوفه بیفزایند.

۸. **داده‌ی گمشده:** برخی فیلدها داده‌ی گمشده‌ی بسیار زیاد دارند. در نظر گرفتن «گمشده» به‌عنوان یک دسته ممکن است اطلاعات را حفظ کند اما می‌تواند فرایندهای گردآوری داده را نیز کدگذاری کند.

۹. **نبود تحلیل علّی رسمی:** ارتباط‌ها و اهمیت ویژگی‌ها روابط علّی را ثابت نمی‌کنند.

۱۰. **توان تفکیک متوسط:** ROC-AUC نزدیک ۰/۶۸ نشان‌دهنده‌ی توان تفکیک محدود است، نه ابزار پیش‌بینی بالینیِ بسیار دقیق.

۱۱. **بار هشدار بالا:** آستانه‌های بازیابی‌محور مثبت‌های کاذب را به‌طور چشمگیری افزایش می‌دهند و بنابراین منابع عملیاتی می‌طلبند.

۱۲. **ارزیابی ناقص زیرگروه‌ها برای مدل نهایی:** معیارهای انصاف برای مدل‌های مرحله‌ی الف محاسبه شد؛ مدل نهایی مرحله‌ی ب برای همه‌ی معیارهای زیرگروه دوباره ارزیابی نشد.

۱۳. **نبود ارزیابی بالینیِ آینده‌نگر:** تحلیل نمی‌سنجد که آیا استفاده از مدل پیامدها را بهبود می‌دهد، بستری مجدد را کاهش می‌دهد یا مصرف خدمات درمانی را کم می‌کند.

۱۴. **قرارداد امتیازدهی زیرگروه‌ها:** گروه‌های بدون مورد مثبت بازیابی صفر می‌گیرند (`zero_division=0`) که شکاف‌های ظاهری را بزرگ می‌کند؛ FNR برای آن گروه‌ها تعریف‌نشده است.

۱۵. **دامنه‌ی انصاف:** انصاف فقط برای مدل‌های مرحله‌ی الف، فقط با بازیابی/FNR و فقط برای نژاد، جنسیت و سن سنجیده شد؛ کالیبراسیون و برابری پیش‌بینی‌کنندگی بررسی نشدند.

۱۶. **آستانه برای مدل تکمیلی:** XGBoost مرحله‌ی ب در آستانه‌ی ثابت ۰/۵۰ ارزیابی شد؛ آستانه‌ی آن دوباره تنظیم نشد و PR-AUC و معیارهای زیرگروه برای آن دوباره محاسبه نگردید. آستانه‌ی ۰/۴۱ به مدل مرحله‌ی الف مربوط است.

۱۷. **عدم قطعیت آستانه:** آستانه روی یک تقسیم اعتبارسنجی انتخاب شد؛ پایداری آن در تقسیم‌های مختلف و بازه‌ی اطمینان بازیابیِ حاصل محاسبه نشد.

۱۸. **بازنمایی:** نمونه عمدتاً قفقازی (۷۴/۷۸٪) و آفریقایی‌آمریکایی (۱۸/۸۸٪) است؛ گروه‌های دیگر کوچک‌اند.

۱۰ پیامدهای عملی

نتایج چند پیامد محتاطانه برای یک جریان کاریِ تحلیلیِ بالینی در آینده را پشتیبانی می‌کند.

نخست، مصرف قبلی خدمات بستری را می‌توان در یک صف بازبینی پس از ترخیص وارد کرد، زیرا سیگنالی بازتولیدپذیر در تحلیل‌های توصیفی و یادگیری ماشین است. دوم، مقصد ترخیص می‌تواند در طبقه‌بندی ریسک نقش داشته باشد، اما باید همراه با زمینه‌ی بالینی تفسیر شود، نه به‌عنوان متغیر علّی قابل‌تغییر. سوم، آستانه‌ی کاری باید بر اساس ظرفیت موجود برای بازبینی انسانی انتخاب شود، نه با بیشینه‌کردن یک معیار عمومی.

یک جریان کاری عملی را می‌توان چنین ساخت (جهت جریان از راست به چپ است):

مراجعه‌ی بیمارستانی ← امتیاز ریسک ← آستانه‌ی مبتنی بر ظرفیت ← بازبینی بالینی انسانی ← پیگیری مناسب.

مدل نباید به‌طور خودکار درمانی را آغاز کند یا خدمتی را رد کند.

۱۰.۱ استفاده برای اولویت‌بندی، نه خودکارسازی

با دقتی در حدود ۱۵ تا ۱۸٪، بیشتر هشدارها کاذب‌اند؛ بنابراین مدل بیشتر برای اولویت‌بندی یک صف بازبینی دستی مناسب است تا برای راه‌اندازی مداخله‌های خودکار. آستانه یک اهرم عملیاتی است: در ۰/۴۱ مدل حدود ۵۹٪ ترخیص‌ها را علامت می‌زند (۱۱٬۸۴۶ از ۱۹٬۹۴۸) و ۷۹/۷٪ بستری‌های مجدد زودهنگام را می‌گیرد، در حالی که در آستانه‌ی پیش‌فرض ۰/۵۰ تقریباً ۳۶٪ را علامت می‌زند (استخراج‌شده) و ۵۹/۸٪ را می‌گیرد؛ آستانه باید بر اساس ظرفیت بازبینی و هزینه‌ی نسبیِ از دست رفتن یک بستری مجدد انتخاب شود. بیمارانی که چند بستری قبلی دارند به‌طور مداوم برجسته‌اند، بنابراین منابع پیگیری (تماس‌های هماهنگی مراقبت، ارجاع به مراقبت در منزل، نوبت‌های پیگیریِ زودهنگام) می‌تواند برای این گروه در اولویت قرار گیرد؛ داده‌ها ارتباط را نشان می‌دهند، نه اینکه این اقدام‌ها بستری مجدد را کاهش دهند.

۱۰.۲ شرایطی که در آن نباید از مدل استفاده کرد

مدل نباید بدون پرداختن به مسئله‌ی سن به کار رود: هر چهار مدل دست‌کم در یک گروه سنی همه‌ی بستری‌های مجدد زودهنگام را از دست می‌دهند. بیماران زیر ۲۰ سال باید کنار گذاشته یا جداگانه اعتبارسنجی شوند، بازیابی در گروه‌های سنی باید با بازه‌های اطمینان گزارش شود، و پیش از هر پایلوت باید کالیبراسیون یا آستانه‌های آگاه از سن در نظر گرفته شود. سرانجام، چون داده‌ها در سال ۲۰۰۸ پایان می‌یابند، هر استقرار واقعی به اعتبارسنجی دوباره روی داده‌ی امروزی نیاز دارد.

پیش از پیاده‌سازی، جریان کار باید به‌صورت آینده‌نگر آزمایش شود. یک پایلوت مفید حجم هشدار، پذیرش پزشکان، زمان بازبینی، تکمیل پیگیری، پیامدهای بستری مجدد، کالیبراسیون و عملکرد زیرگروه‌ها را اندازه می‌گرفت. هر تغییری در پیامد بالینی باید با طرح مطالعه‌ی مناسب ارزیابی شود، نه اینکه از عملکرد پیش‌بینی استنباط گردد.

۱۱ بازتولیدپذیری و محیط محاسباتی

پروژه با پایتون پیاده‌سازی شد: pandas و NumPy برای پردازش داده؛ SciPy برای محاسبات آماری؛ scikit-learn برای پیش‌پردازش، تقسیم‌بندی، مدل‌سازی، اعتبارسنجی متقاطع و معیارها؛ XGBoost برای تقویت گرادیانی؛ و Seaborn/Matplotlib برای مصورسازی.

جدول ۱۷: محیط محاسباتی و اجزای تحلیلی.

دسته	ابزارها
برنامه‌نویسی	Python 3.13.5 در محیط اصلی گزارش شده است
پردازش داده	pandas, NumPy
آمار	SciPy، روش‌های جدول پیشامد، اندازه‌های اثر
یادگیری ماشین	scikit-learn, XGBoost
اعتبارسنجی	`GroupShuffleSplit`، `StratifiedGroupKFold`، `RandomizedSearchCV`
مصورسازی	Matplotlib, Seaborn
محیط	Jupyter Notebook / Anaconda

پروژه‌ی اصلی از یک مسیر نسبی برای داده استفاده می‌کند و شکل‌ها را در پوشه‌ی `Figures/` ذخیره می‌کند. بازتولید عددی دقیق ممکن است با نسخه‌ی کتابخانه‌ها اندکی تفاوت کند، اما بذر اصلی تقسیم ۱۲۳ است.

بذر تصادفی برای تقسیم آموزش/آزمون، تقسیم اعتبارسنجی، مدل‌ها و جست‌وجوی ابرپارامتر ۱۲۳ است. نسخه‌ی بسته‌ها در پروژه‌ی اصلی ثبت نشد و هنگام ثابت‌کردن محیط باید قفل شود. دفترچه داده را با مسیر نسبیِ سبک ویندوز می‌خواند که در مک‌اواس یا لینوکس باید تغییر کند، و باید از درون پوشه‌ی خودش اجرا شود تا مسیرهای نسبی درست حل شوند. نقاط بازرسیِ مورد انتظار عبارت‌اند از جدول داده‌ی خامِ $101{,}766 \times 50$، هم‌گروه مدل‌سازی با ۹۹٬۳۴۳ مراجعه، تقسیم آموزش/آزمون با ۷۹٬۳۹۵ و ۱۹٬۹۴۸ مراجعه، و هم‌پوشانی صفر بیمار.

یک داشبورد HTML تعاملی (Chart.js، با پالایه‌های سن و جنسیت) همراه پروژه است. این داشبورد توزیع پیامد دودویی، دو نمودار آستانه‌ی XGBoost (۰/۴۱ و پیش‌فرض ۰/۵۰، ارزیابی‌شده روی مجموعه‌ی آزمون نگه‌داشته‌شده و بنابراین بی‌اثر از پالایه‌ها) و یک کارت هشدار انصاف سنی را نشان می‌دهد که شکاف‌های FNR نژاد، جنسیت و سن را برای هر چهار مدل خلاصه می‌کند.

۱۲ نتیجه‌گیری

این پژوهش یک گردش کار کامل علم داده‌های پزشکی را برای پیش‌بینی بستری مجدد ظرف ۳۰ روز در بیماران بستری مبتلا به دیابت ارائه می‌دهد. تحلیل، بازبینی کیفیت داده، اپیدمیولوژی توصیفی، اندازه‌های اثر تفسیرپذیر، یادگیری ماشین آگاه از نشت، بهینه‌سازی آستانه و تحلیل خطای زیرگروه‌ها را با هم ترکیب می‌کند.

قوی‌ترین سیگنال تکرارشونده مصرف قبلی خدمات بستری است، در حالی که مقصد ترخیص بزرگ‌ترین ارتباط طبقه‌ای و یک ویژگی برجسته‌ی مدل را فراهم می‌کند. با این حال، بیشتر ارتباط‌های تکی کوچک‌اند و مدل‌های پیش‌بینی تنها توان تفکیک متوسطی دارند. XGBoost به ROC-AUC حدود ۰/۶۸ رسید، و آستانه‌گذاریِ بازیابی‌محور حساسیت را به‌طور چشمگیری افزایش داد، به بهای بار بزرگ مثبت‌های کاذب.

این مطالعه همچنین نشان می‌دهد چرا پیش‌بینی در سلامت نباید به یک عدد صحت فروکاسته شود. تقسیم‌بندی در سطح بیمار از یک شکل مهم نشت جلوگیری می‌کند، PR-AUC در عدم توازن کلاس‌ها آگاهی‌بخش است، و معیارهای زیرگروه به زمینه‌ی اندازه‌ی نمونه نیاز دارند. نتایج انصاف گروه‌های سنی نشان می‌دهد وقتی موارد مثبت نادرند، برآوردهای ظاهراً چشمگیرِ نابرابری چقدر می‌توانند ناپایدار باشند.

بنابراین تفسیر مناسب محافظه‌کارانه است: مدل می‌تواند از اولویت‌بندی و بازبینی انسانی پشتیبانی کند، اما نباید تصمیم‌گیرنده‌ی بالینیِ خودمختار تلقی شود. اعتبارسنجی بیرونیِ معاصر، کالیبراسیون، کمّی‌سازی عدم قطعیت، ارزیابی زیرگروه‌ها و سنجش آینده‌نگر اثر بالینی، گام‌های لازم پیش از هر کاربرد واقعی است.

دسترس‌پذیری داده

تحلیل از مجموعه‌داده‌ی عمومی «دیابت، ۱۳۰ بیمارستان آمریکا، سال‌های ۱۹۹۹ تا ۲۰۰۸» استفاده می‌کند که از طریق مخزن یادگیری ماشین UCI با مجوز CC BY 4.0 منتشر شده است. آرشیو پروژه‌ی ارائه‌شده شامل فایل‌های داده، دفترچه و شکل‌های تولیدشده‌ی مورد استفاده برای این دست‌نوشته است.

بیانیه‌ی اخلاق و کاربرد بالینی

این یک تحلیل ثانویه روی مجموعه‌داده‌ی عمومیِ بدون شناسه است. این دست‌نوشته هیچ توصیه‌ی بالینی در سطح فرد ارائه نمی‌کند. نتایج پیش‌بینی برای تحلیل روش‌شناختی و آموزشی ارائه شده‌اند و بدون اعتبارسنجی بالینیِ مستقل و حکمرانی مناسب نباید مستقیماً در مراقبت از بیمار به کار روند.

الف تعداد دقیق خطاهای مدل‌ها

جدول ۱۸: تعداد خطاها در آستانه‌های بازیابی‌محور مرحله‌ی الف.

مدل	TP	FN	FP	TN	FNR
رگرسیون لجستیک	۱,۷۸۷	۴۷۳	۱۰,۵۳۹	۷,۱۴۹	۰/۲۰۹
درخت تصمیم	۱,۷۷۶	۴۸۴	۱۰,۶۰۸	۷,۰۸۰	۰/۲۱۴
جنگل تصادفی	۱,۸۷۶	۳۸۴	۱۱,۰۶۹	۶,۶۱۹	۰/۱۷۰
XGBoost	۱,۸۰۲	۴۵۸	۱۰,۰۴۴	۷,۶۴۴	۰/۲۰۳

ب ممیزی سازگاری و تفسیر

پروژه‌ی ارائه‌شده خروجی‌های متعددی دارد که مراحل تحلیلیِ متفاوتی را نمایندگی می‌کنند. دست‌نوشته‌ی حاضر عمداً آن‌ها را از هم تفکیک می‌کند، نه اینکه یک عدد واحد را به همه‌ی بخش‌ها تحمیل کند.

جدول ۱۹: تمایزهای تحلیلیِ کلیدی که در این دست‌نوشته حفظ شده‌اند.

موضوع	مرحله‌ی الف	مرحله‌ی ب / نهایی
پارامترهای XGBoost	پیکربندی ثابت ۲۵۰ درختی	پیکربندی انتخاب‌شده با `RandomizedSearchCV`
آستانه	تنظیم‌شده روی اعتبارسنجی؛ ۰/۴۱ برای XGBoost	ثابت روی ۰/۵۰
بازیابی XGBoost	۰/۷۹۷	۰/۶۱۹
دقت XGBoost	۰/۱۵۲	۰/۱۸۱
ROC-AUC مدل XGBoost	۰/۶۸۳	تقریباً ۰/۶۸
هدف	مقایسه‌ی نقاط کاری	گزارش مدل نهایی جست‌وجوشده
معیارهای انصاف	محاسبه شده	به‌طور کامل دوباره محاسبه نشده

این تمایز مانع می‌شود خواننده دو پیکربندی متفاوت مدل را یک آزمایش واحد بپندارد.

ناسازگاری‌های میان شرح دفترچه و خروجی‌های اجراشده

در طول آماده‌سازی، توضیحات نوشتاریِ دفترچه با خروجی‌های اجراشده‌اش مقایسه شد. خروجی‌های اجراشده (نتایج ذخیره‌شده‌ی سلول‌ها) قابل‌اعتمادترین منبع تلقی شدند.

جدول ۲۰: ممیزی سازگاریِ دفترچه‌ی منبع.

ردیف	مسئله و آنچه خروجی اجراشده نشان می‌دهد	راه‌حل به‌کاررفته
۱	متن «مدل منتخب – XGBoost» می‌گوید XGBoost در آستانه‌ی ۰/۵۰ بیشترین بازیابی (۰/۸۰۰) و ROC-AUC برابر ۰/۶۸۴ را داشت. در ۰/۵۰، بازیابی XGBoost برابر ۰/۵۹۸ است و درخت تصمیم بیشترین (۰/۶۵۹) را دارد؛ پس از تنظیم، جنگل تصادفی بیشترین بازیابی (۰/۸۳۰) را دارد؛ ROC-AUC مدل XGBoost برابر ۰/۶۸۳ است. هیچ خروجی اجراشده‌ای بازیابی ۰/۸۰۰ را برای XGBoost نشان نمی‌دهد (ممکن است از اجرای قبلی باشد).	XGBoost به دلیل بهترین ROC-AUC، PR-AUC، صحت متوازن و F1 توجیه می‌شود، نه به دلیل بیشترین بازیابی.
۲	شرح پرسش ۹ مدل «قهرمان» XGBoost را در آستانه‌ی ۰/۴۱ با بازیابی ۰/۷۹۷ توصیف می‌کند، اما سلول‌های پایانی XGBoost را با RandomizedSearchCV دوباره برازش می‌دهند و در آستانه‌ی ۰/۵۰ ارزیابی می‌کنند (بازیابی ۰/۶۱۹).	به‌عنوان مرحله‌ی الف (ابرپارامترهای ثابت، آستانه‌ی تنظیم‌شده‌ی ۰/۴۱) و مرحله‌ی ب (ابرپارامترهای جست‌وجوشده، آستانه‌ی ۰/۵۰، تکمیلی) گزارش شد.
۳	شرح انصاف از «سوگیری الگوریتمیِ شدید» بر حسب سن و min_Recall = 0.000 برای جنسیت سخن می‌گوید. شکاف FNR سن ۰/۸۸۵ تا ۰/۹۶۷ است و در هر چهار مدل دست‌کم در یک گروه FNR = 1.00 است؛ آن گروه‌ها ۱ و ۶ مورد مثبت دارند. صفر جنسیت از یک گروه «گمشده»ی تک‌مراجعه‌ای بدون مورد مثبت ناشی می‌شود. انصاف فقط برای مدل‌های مرحله‌ی الف محاسبه شد.	نابرابری سنی به‌عنوان یافته‌ی بحرانی همراه با عدم قطعیت نمونه‌ی کوچک گزارش شد؛ صفرِ جنسیت به‌عنوان مصنوع داده توضیح داده شد.
۴	دو اندازه‌ی هم‌گروه و شیوع ظاهر می‌شود: تحلیل اکتشافی ۱۰۱,۷۶۶ مراجعه (۱۱/۱۶٪) دارد؛ مدل‌سازی پس از حذف ۲,۴۲۳ ترخیص فوت/هاسپیس ۹۹,۳۴۳ مراجعه (۱۱/۳۹٪) دارد.	هر دو گزارش و بر حسب مرحله برچسب‌گذاری شدند.
۵	متن دفترچه می‌گوید PR-AUC مدل XGBoost برابر ۰/۲۳۸ و ROC-AUC برابر ۰/۶۸۴ است؛ خروجی ۰/۲۳۸ و ۰/۶۸۳ را نشان می‌دهد.	۰/۶۸۳ به‌کار رفت (تفاوت گردکردن).
۶	عنوان و نام فایل دفترچه‌ی اصلی با نسخه‌های نقطه‌ی بازرسی‌اش تفاوت دارد؛ پوشه‌ی نقطه‌ی بازرسی یک نسخه‌ی قدیمی‌تر با نام متفاوت دارد.	فقط project-04.ipynb به‌عنوان منبع مرجع به کار رفت.

پ واژه‌نامه‌ی اصطلاحات آماری

برای اطمینان از یکدستی ترجمه، معادل فارسی اصطلاحات آماری و یادگیری ماشین که در این مقاله به کار رفته‌اند در جدول زیر گردآوری شده است.

جدول ۲۱: واژه‌نامه‌ی اصطلاحات آماری (انگلیسی به فارسی).

اصطلاح انگلیسی	معادل فارسی
Accuracy	صحت
Precision (PPV)	دقت (ارزش اخباری مثبت)
Recall / Sensitivity	بازیابی (حساسیت)
False Negative Rate (FNR)	نرخ منفی کاذب
Balanced Accuracy	صحت متوازن
Confusion Matrix	ماتریس درهم‌ریختگی
ROC Curve / AUC	منحنی مشخصه‌ی عملکرد گیرنده / مساحت زیر منحنی
Precision–Recall Curve	منحنی دقت–بازیابی
Class Imbalance	عدم توازن کلاس‌ها
Standardized Mean Difference (SMD)	تفاوت میانگین استانداردشده
Effect Size	اندازه‌ی اثر
Cramér’s V	ضریب V کرامر
Pearson Correlation	همبستگی پیرسون
Interquartile Range (IQR)	دامنه‌ی بین‌چارکی
Outlier	داده‌ی پرت
Imputation	جای‌گذاری مقادیر گمشده
Cross-Validation	اعتبارسنجی متقاطع
Hyperparameter	ابرپارامتر
Decision Threshold	آستانه‌ی تصمیم
Calibration	کالیبراسیون (واسنجی)
Confidence Interval	بازه‌ی اطمینان
Data Leakage	نشت داده
Cohort	هم‌گروه
Held-out Test Set	مجموعه‌ی آزمون نگه‌داشته‌شده
Subgroup Analysis	تحلیل زیرگروه‌ها
One-hot Encoding	کدگذاری یک‌داغ
Zero-inflated	صفر–متورم
Lift	نسبت افزایش
Logistic Regression	رگرسیون لجستیک
Decision Tree	درخت تصمیم
Random Forest	جنگل تصادفی
Gradient Boosting	تقویت گرادیانی

مراجع

[۱] B. Strack, J. P. DeShazo, C. Gennings, J. L. Olmo, S. Ventura, K. J. Cios, and J. N. Clore, “Impact of HbA1c measurement on hospital readmission rates: Analysis of 70,000 clinical database patient records,” *BioMed Research International*, vol. 2014, Article 781670, 2014. doi:10.1155/2014/781670.

[۲] J. Clore, K. Cios, J. DeShazo, and B. Strack, *Diabetes 130-US Hospitals for Years 1999–2008*. UCI Machine Learning Repository, 2014. Available at: `https://archive.ics.uci.edu/dataset/296/diabetes-130-us-hospitals-for-years-1999-2008`.

[۳] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016. doi:10.1145/2939672.2939785.

[۴] F. Pedregosa, G. Varoquaux, A. Gramfort, et al., “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[۵] C. R. Harris, K. J. Millman, S. J. van der Walt, et al., “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020. doi:10.1038/s41586-020-2649-2.

[۶] P. Virtanen, R. Gommers, T. E. Oliphant, et al., “SciPy 1.0: Fundamental algorithms for scientific computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020. doi:10.1038/s41592-019-0686-2.

[۷] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007. doi:10.1109/MCSE.2007.55.

[۸] M. L. Waskom, “Seaborn: Statistical data visualization,” *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021. doi:10.21105/joss.03021.

[۹] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum Associates, 1988.

[۱۰] H. Cramér, *Mathematical Methods of Statistics*. Princeton University Press, 1946.